

Klasifikasi Citra Jenis Kulit Wajah dengan Menggunakan
Hybrid MobileNet-SVM Dengan Optimasi Fine Tuning

SKRIPSI

Diajukan untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi Informatika



disusun oleh

AZHAR RIZQULLAH

22.11.4981

Kepada

FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA
2026

**Klasifikasi Citra Jenis Kulit Wajah dengan Menggunakan
*Hybrid MobileNet-SVM Dengan Optimasi Fine Tuning***

SKRIPSI

untuk memenuhi salah satu syarat mencapai derajat Sarjana
Program Studi Informatika



disusun oleh

AZHAR RIZQULLAH

22.11.4981

Kepada

**FAKULTAS ILMU KOMPUTER
UNIVERSITAS AMIKOM YOGYAKARTA
YOGYAKARTA
2026**

HALAMAN PERSETUJUAN

SKRIPSI

**KLASIFIKASI CITRA JENIS KULIT WAJAH DENGAN
MENGUNAKAN *HYBRID MOBILENET-SVM* DENGAN OPTIMASI
*FINE TUNING***

yang disusun dan diajukan oleh

Azhar Rizqullah

22.11.4981

telah disetujui oleh Dosen Pembimbing Skripsi
pada tanggal 20 Januari 2026

Dosen Pembimbing,



Dr. Emigawaty, M.Kom

NIK. 190302226

HALAMAN PENGESAHAN
SKRIPSI
KLASIFIKASI CITRA JENIS KULIT WAJAH DENGAN
MENGGUNAKAN *HYBRID MOBILENET-SVM* DENGAN OPTIMASI
FINE TUNING

yang disusun dan diajukan oleh

Azhar Rizqullah

22.11.4981

Telah dipertahankan di depan Dewan Penguji
Pada tanggal 20 Januari 2026

Susunan Dewan Penguji

Nama Penguji

Tanda Tangan

Ferian Fauzi Abdulloh, S.Kom., M.Kom.
NIK. 190302276



Anna Baita, S.Kom., M.Kom.
NIK. 190302290



Dr. Emigawaty, M.Kom.
NIK. 190302226



Skripsi ini telah diterima sebagai salah satu persyaratan
untuk memperoleh gelar Sarjana Komputer
Tanggal 20 Januari 2026

DEKAN FAKULTAS ILMU KOMPUTER



Prof. Dr. Kusrini, M.Kom.
NIK. 190302106

HALAMAN PERNYATAAN KEASLIAN SKRIPSI

Yang bertandatangan di bawah ini,

Nama mahasiswa : Azhar Rizqullah
NIM : 22.11.4981

Menyatakan bahwa Skripsi dengan judul berikut:

Klasifikasi Citra Jenis Kulit Wajah dengan Menggunakan *Hybrid MobileNet-SVM* Dengan *Optimasi Fine Tuning*

Dosen Pembimbing : Dr. Emigawaty, M.Kom.

1. Karya tulis ini adalah benar-benar ASLI dan BELUM PERNAH diajukan untuk mendapatkan gelar akademik, baik di Universitas AMIKOM Yogyakarta maupun di Perguruan Tinggi lainnya.
2. Karya tulis ini merupakan gagasan, rumusan dan penelitian SAYA sendiri, tanpa bantuan pihak lain kecuali arahan dari Dosen Pembimbing.
3. Dalam karya tulis ini tidak terdapat karya atau pendapat orang lain, kecuali secara tertulis dengan jelas dicantumkan sebagai acuan dalam naskah dengan disebutkan nama pengarang dan disebutkan dalam Daftar Pustaka pada karya tulis ini.
4. Perangkat lunak yang digunakan dalam penelitian ini sepenuhnya menjadi tanggung jawab SAYA, bukan tanggung jawab Universitas AMIKOM Yogyakarta.
5. Pernyataan ini SAYA buat dengan sesungguhnya, apabila di kemudian hari terdapat penyimpangan dan ketidakbenaran dalam pernyataan ini, maka SAYA bersedia menerima SANKSI AKADEMIK dengan pencabutan gelar yang sudah diperoleh, serta sanksi lainnya sesuai dengan norma yang berlaku di Perguruan Tinggi.

Yogyakarta, Selasa, 20 Januari 2026

Yang Menyatakan,



Azhar Rizqullah

HALAMAN PERSEMBAHAN

Alhamdulillah, segala puji dan syukur penulis panjatkan ke hadirat Allah SWT, Tuhan Yang Maha Esa, atas limpahan rahmat, hidayah, dan karunia-Nya sehingga penulis dapat menyelesaikan karya skripsi ini dengan baik. Tanpa pertolongan, karunia, dan lindungan-Nya, tentu tidak mungkin penulis mampu melewati setiap tantangan dan hambatan dalam proses penyusunan skripsi ini. Semoga setiap langkah dan usaha yang penulis jalani senantiasa berada dalam ridho dan keberkahan-Nya. Skripsi ini penulis persembahkan kepada:

1. Ayah penulis, Hasbian Noor, yang senantiasa menjadi sosok teladan dalam keteguhan, tanggung jawab, dan kerja keras. Dukungan, doa, serta nasihat yang diberikan dengan penuh kesabaran telah menjadi pondasi kuat bagi penulis dalam menempuh proses pendidikan dan menyelesaikan skripsi ini.
2. Ibu penulis, Asiyah, yang dengan kasih sayang tanpa batas, doa yang tidak pernah terputus, serta perhatian yang tulus selalu menyertai setiap langkah penulis. Dukungan ibu menjadi sumber kekuatan utama bagi penulis dalam menghadapi berbagai tantangan selama proses penyusunan skripsi ini.
3. Dosen pembimbing penulis, Dr. Emigawaty, M.Kom., yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, arahan, ilmu, serta masukan yang sangat berharga. Kesabaran dan ketelitian beliau sangat membantu penulis dalam menyelesaikan skripsi ini dengan baik.
4. Sahabat, orang-orang terdekat, teman-teman magang, teman-teman Studi Independen Batch 7, teman-teman Asrama Mahasiswa Kabupaten Sambas, serta teman-teman sekelas yang telah memberikan dukungan moral, semangat, kebersamaan, dan pengalaman berharga selama perjalanan akademik penulis.
5. Keponakan penulis, Habrizi Muhammad Ukasya, serta para keponakan online penulis, yang telah menghadirkan warna, keceriaan, dan semangat

dalam kehidupan penulis. Meskipun tidak seluruhnya penulis kenal secara langsung maupun mengetahui nama lengkapnya satu per satu, kehadiran dan interaksi mereka memberikan energi positif, kebahagiaan, serta motivasi tersendiri bagi penulis untuk terus menjalani setiap proses dengan lebih optimis.

6. Untuk seseorang yang belum dapat penulis sebutkan namanya secara jelas dalam karya ini, namun sudah tertulis jelas di Lauhul Mahfudz. Terima kasih atas keberadaannya yang secara tidak langsung menjadi sumber motivasi bagi penulis dalam proses pendewasaan diri, pembelajaran hidup, dan perbaikan diri ke arah yang lebih baik.
7. Seluruh pihak lain yang tidak dapat penulis sebutkan satu per satu, yang telah turut memberikan doa, dukungan, dan bantuan kepada penulis selama proses penyusunan skripsi ini.
8. Terakhir, penulis mengucapkan terima kasih kepada diri penulis sendiri, Azhar Rizqullah, yang telah berusaha dengan sungguh-sungguh, mampu bertahan di tengah berbagai tekanan, serta tidak menyerah dalam menghadapi setiap proses hingga berhasil menyelesaikan skripsi ini sebagai salah satu tahap akhir pendidikan sarjana.

KATA PENGANTAR

Segala puji dan syukur penulis panjatkan ke hadirat Allah SWT yang telah melimpahkan rahmat, taufik, dan hidayah-Nya sehingga penulis dapat menyelesaikan skripsi berjudul “Klasifikasi Citra Jenis Kulit Wajah dengan Menggunakan Hybrid MobileNet-SVM Dengan Optimasi Fine Tuning” sebagai syarat memperoleh gelar Sarjana Komputer di Universitas AMIKOM Yogyakarta.

Dalam proses penyusunan skripsi ini, penulis tidak lepas dari bimbingan, dukungan, dan doa dari berbagai pihak. Dengan segala kerendahan hati, penulis mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Prof. Dr. M. Suyanto, M.M selaku Rektor Universitas AMIKOM Yogyakarta yang telah memberikan kesempatan kepada penulis untuk menimba ilmu di kampus ini.
2. Dr. Emigawaty, M.Kom selaku dosen pembimbing yang telah memberikan bimbingan, saran, dan motivasi yang berharga selama proses penyusunan skripsi ini.
3. Kedua orang tua penulis yang telah memberikan dukungan, serta doa selama hidup penulis, sehingga sampai saat ini skripsi penulis dapat terselesaikan dengan baik.
4. Seluruh dosen dan staf Universitas AMIKOM Yogyakarta yang telah memberikan ilmu dan bantuan selama penulis menempuh studi.
5. Semua teman-teman serta sahabat penulis yang sudah menemani penulis dari awal kuliah hingga saat ini dan selalu memberikan dukungan serta doa agar penulis tetap semangat dalam penyelesaian skripsi ini.

Penulis menyadari bahwa skripsi ini masih memiliki banyak kekurangan. Kritik dan saran yang membangun sangat penulis harapkan demi kesempurnaan di masa mendatang. Semoga skripsi ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang computer vision dan kesehatan kulit.

Yogyakarta, 15 Desember 2025

Penulis

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PERSETUJUAN.....	ii
HALAMAN PENGESAHAN	iii
HALAMAN PERNYATAAN KEASLIAN SKRIPSI	iv
HALAMAN PERSEMBAHAN	v
KATA PENGANTAR	vii
DAFTAR ISI.....	viii
DAFTAR TABEL	xi
DAFTAR GAMBAR	xii
DAFTAR LAMBANG DAN SINGKATAN	xiii
DAFTAR ISTILAH	xv
INTISARI	xvii
ABSTRACT.....	xviii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah.....	3
1.4 Tujuan Penelitian.....	4
1.5 Manfaat Penelitian.....	4
1.6 Sistematika Penulisan.....	5
BAB II TINJAUAN PUSTAKA	6
2.1 Studi Literatur	6
2.2 Dasar Teori	10
2.2.1 Machine Learning	10
2.2.2 Klasifikasi	10
2.2.3 Jenis Kulit Wajah.....	10
2.2.4 Convolutional Neural Network (CNN).....	11
2.2.5 MobileNet	12
2.2.6 Transfer Learning.....	13
2.2.7 Support Vector Machine (SVM).....	13
2.2.8 Metrik Evaluasi	14
BAB III METODE PENELITIAN	15

3.1	Objek Penelitian	15
3.2	Alur Penelitian.....	15
3.2.1	Identifikasi Masalah.....	16
3.2.2	Studi Literatur	17
3.2.3	Akuisisi Data.....	17
3.2.4	Pra-pemrosesan Data	17
3.2.5	Pembuatan Model	18
3.2.6	Evaluasi dan Optimasi	19
3.2.7	Pembuatan UI/UX.....	19
3.2.8	Integrasi Frontend dan Backend Web.....	20
3.2.9	Pengujian Lokal	20
3.2.10	Deployment.....	20
3.2.11	Kesimpulan dan Saran	21
3.3	Alat dan Bahan	21
3.3.1	Data Penelitian	21
3.3.2	Instrumen Penelitian	21
BAB IV HASIL DAN PEMBAHASAN		24
4.1	Akuisisi dan Eksplorasi Dataset.....	24
4.1.1	Sumber dan Struktur Dataset	24
4.1.2	Distribusi Kelas	24
4.1.3	Analisis Distribusi Data.....	26
4.2	Pra-Pemrosesan dan Augmentasi Data	27
4.2.1	Visualisasi Sampel Data Asli	27
4.2.2	Teknik Normalisasi Pixel menggunakan MobileNetV2 Preprocessing 28	
4.2.3	Parameter Augmentasi Data yang Diterapkan.....	28
4.2.4	Visualisasi Hasil Augmentasi (8 gambar hasil transformasi).....	29
4.3	Pembuatan dan Pelatihan Model Klasifikasi.....	30
4.3.1	Arsitektur Model Hybrid MobileNetV2 dengan RBF-SVM.....	30
4.3.2	Implementasi Transfer Learning dan Fine-Tuning (unfreeze 80 layer terakhir) 30	
4.3.3	Proses Pelatihan Model CNN dengan Callbacks.....	32
4.3.4	Analisis Kurva Akurasi dan Loss (Training vs Validation)	34
4.3.5	Ekstraksi Fitur menggunakan Model Terbaik dan Persiapan Pelatihan RBF-SVM	36

4.3.6	Normalisasi Fitur dan Pelatihan Classifier RBF-SVM.....	38
4.3.7	Hasil GridSearchCV dan Parameter Optimal SVM	39
4.3.8	Evaluasi Performa Model Hybrid Akhir pada Data Pengujian Independen	40
4.3.9	Perbandingan Performa Model	43
4.3.10	Analisis Kesalahan Klasifikasi (Error Analysis)	45
4.3.11	Pengujian Efisiensi Komputasi Model	47
4.4	Implementasi Sistem ke Dalam Aplikasi Web.....	50
4.4.1	Desain Antarmuka Pengguna (UI/UX)	50
4.4.2	Integrasi Frontend dan Backend	52
4.4.3	Pengujian Lokal dan Error Handling	52
4.5	Deployment	54
BAB V PENUTUP		56
5.1	Kesimpulan.....	56
5.2	Saran.....	57
REFERENSI		58

DAFTAR TABEL

Tabel 2.1. Keaslian Penelitian	8
Tabel 2.1. Lanjutan	9
Tabel 4. 1 Tabel Rincian per kelas.....	26
Tabel 4. 2 Parameter Augmentasi	28
Tabel 4. 3. Ringkasan Performa pada Beberapa Epoch Penting.....	33
Tabel 4. 4. Hasil ekstraksi fitur.....	37
Tabel 4. 5. Ringkasan Hasil Ekstraksi Fitur.....	37
Tabel 4. 6. Ruang Pencarian Hyperparameter RBF-SVM.....	39
Tabel 4. 7. Parameter RBF-SVM Terbaik	40
Tabel 4. 8. Classification Report Model Hybrid Akhir	41
Tabel 4. 9. Perbandingan Performa Model pada Data Pengujian	43
Tabel 4. 10 Hasil pengujian efisiensi	47
Tabel 4. 11. Error Handling yang Diimplementasikan	53

DAFTAR GAMBAR

Gambar 2.1 Proses CNN pada Inverted Residual Block.	11
Gambar 4. 1. Tabel Distribusi Dataset Tabel Distribusi Dataset Sumber: Hasil eksekusi kode pada Kaggle Notebook.	25
Gambar 4. 2. Diagram Batang Distribusi Jumlah Gambar per Kelas pada Set Train, Validation, dan Test Diagram Batang Distribusi.	25
Gambar 4. 3. Gambar Asli per Kelas	27
Gambar 4. 4. Hasil Augmentasi Data.	29
Gambar 4. 5. Ringkasan Arsitektur Model Hybrid MobileNetV2 setelah fine-tuning	31
Gambar 4. 6. Kurva Akurasi Model Selama Pelatihan.	34
Gambar 4. 7. Kurva Loss Model Selama Pelatihan	35
Gambar 4. 8. Confusion Matrix Model Hybrid. (MobileNetV2 dengan RBF-SVM)	41
Gambar 4. 9. Dua Belas Contoh Kesalahan Klasifikasi Model Hybrid.....	45
Gambar 4. 10. Perbandingan Waktu Inferensi Rata-rata per Citra	47
Gambar 4. 11. Perbandingan Ukuran Model Akhir	48
Gambar 4. 12. Tampilan Halaman Utama Aplikasi FACEDX.....	51
Gambar 4. 13. Proses Upload Foto dan Hasil Prediksi.....	51
Gambar 4. 14. Contoh Error Handling Wajah Tidak Terdeteksi	53
Gambar 4. 15. Aplikasi FACEDX dalam Keadaan Live	54

DAFTAR LAMBANG DAN SINGKATAN

API	Application Programming Interface
b	Bias pada hyperplane SVM
C_{in}	Jumlah kanal masukan (input channels)
C_{out}	Jumlah kanal keluaran (output channels)
CNN	Convolutional Neural Network
CPU	Central Processing Unit
CSS	Cascading Style Sheets
FN	False Negative
FP	False Positive
GAP	Global Average Pooling
GPU	Graphics Processing Unit
HTML	HyperText Markup Language
(i,j)	Koordinat piksel pada citra atau feature map
JS	JavaScript
JSON	JavaScript Object Notation
k	Ukuran kernel ($k \times k$)
MobileNetV2	Mobile Neural Network Version 2
Precision	Presisi
RAM	Random Access Memory
RBF	Radial Basis Function
ReLU	Rectified Linear Unit
RESTful	Representational State Transfer
$\text{sign}(\cdot)$	Fungsi tanda (signum)
StandardScaler	Normalisasi fitur (mean=0, std=1)
Σ	Penjumlahan (sigma)
SVM	Support Vector Machine
TN	True Negative
TP	True Positive

UI	User Interface
UX	User Experience
w	Vektor bobot pada SVM
w^T	Transpos vektor bobot
$\ w\ $	Norma Euclidean vektor bobot
$*$	Operasi konvolusi

DAFTAR ISTILAH

Accuracy	Persentase prediksi benar secara keseluruhan.
Augmentasi Data	Pembuatan variasi citra baru dari data asli.
BatchNormalization	Normalisasi aktivasi tiap layer untuk stabilkan training.
Batch Size	Jumlah sampel diproses dalam satu iterasi.
Confusion Matrix	Tabel kesalahan klasifikasi (TP/TN/FP/FN).
Dropout	Mematikan neuron acak untuk cegah overfitting.
Epoch	Satu kali latih seluruh data pelatihan.
F1-Score	Rata-rata harmonik precision dan recall.
FACEDX	Nama aplikasi web hasil penelitian ini.
Fine-Tuning	Penyesuaian layer model pre-trained pada data baru.
Flask	Micro web framework Python.
Global Average Pooling	Pooling rata-rata seluruh feature map.
GridSearchCV	Pencarian hyperparameter terbaik otomatis.
Gunicorn	Server produksi untuk Flask.
Haar Cascade	Algoritma deteksi wajah cepat.
Hyperparameter	Parameter ditentukan sebelum training.
ImageDataGenerator	Generator augmentasi real-time pada Keras.
Inference	Proses prediksi model pada data baru.
Learning Rate	Besar langkah pembaruan bobot saat training.
Loss	Nilai kesalahan prediksi model.
MobileNetV2	Arsitektur CNN ringan buatan Google.
Melasma	Bercak gelap di kulit wajah
Overfitting	Model terlalu hafal data latih, jelek di data baru.
Overlap	Tumpang tindih fitur antar kelas (dry-normal).
Precision	Proporsi prediksi positif yang benar.
Preprocessing	Persiapan data sebelum masuk model.
Railway	Platform deployment aplikasi web.
RBF-SVM	SVM dengan kernel Radial Basis Function.
React.js	Library JavaScript untuk UI.

Recall	Proporsi data positif yang terdeteksi
RESTful API	API berbasis HTTP dengan format JSON.
Roboflow	Platform sumber dataset citra kulit wajah.
StandardScaler	Normalisasi fitur (mean=0, std=1).
Tailwind CSS	Framework CSS utility-first.
Transfer Learning	Memanfaatkan model pre-trained pada tugas baru.
Validation	Evaluasi model pada data terpisah selama training.
Vite	Build tool cepat untuk React.
Web Application	Aplikasi yang diakses lewat browser.

INTISARI

Klasifikasi jenis kulit wajah secara manual masih bersifat subjektif, memakan waktu, dan sering tidak konsisten, sehingga menyulitkan pemilihan produk perawatan yang tepat serta meningkatkan risiko iritasi atau jerawat. Penelitian ini mengembangkan sistem deteksi otomatis jenis kulit wajah (*acne*, *dry*, *normal*, *oily*) menggunakan pendekatan hybrid MobileNetV2 fine-tuned dan RBF-SVM. Dataset sebanyak 2.000 citra dari Roboflow melalui tahap augmentasi intensif, fine-tuning mendalam pada MobileNetV2, ekstraksi fitur 1280-dimensi, normalisasi dengan StandardScaler, serta pelatihan RBF-SVM dengan hyperparameter optimal ($C = 30$, $\gamma = 0,001$) hasil GridSearchCV 5-fold. Sistem dilengkapi deteksi wajah Haar Cascade untuk keandalan pada kondisi real-world.

Model hybrid menghasilkan akurasi pengujian tertinggi 90,31% (macro F1-score 0,90) pada data uji independen 196 citra, melampaui baseline tanpa fine-tuning sebesar 15,31 poin dan varian CNN-softmax sebesar 4,95 poin. Seluruh pipeline telah diimplementasikan menjadi aplikasi web publik FACEDX berbasis React.js dengan Tailwind CSS (frontend) dan Flask dengan Gunicorn (backend), yang dideploy pada Railway dengan domain kustom serta error handling lengkap. Aplikasi ini dapat dimanfaatkan masyarakat umum, dokter kulit, dan industri kosmetik untuk rekomendasi perawatan yang lebih akurat dan personal.

Kata kunci: klasifikasi kulit wajah, MobileNetV2, RBF-SVM, transfer learning, aplikasi web satu, dua, tiga, empat, lima.

ABSTRACT

Manual classification of facial skin types remains subjective, time-consuming, and inconsistent, complicating appropriate skincare selection and increasing risks of irritation or acne. This research developed an automatic facial skin type detection system (acne, dry, normal, oily) using a hybrid fine-tuned MobileNetV2 and RBF-SVM approach. A dataset of 2,000 images from Roboflow underwent intensive augmentation, deep fine-tuning of MobileNetV2, 1280-dimensional feature extraction, StandardScaler normalization, and RBF-SVM training with optimal hyperparameters ($C = 30$, $\gamma = 0.001$) obtained via 5-fold GridSearchCV. The system incorporates Haar Cascade face detection for real-world robustness.

The final hybrid model achieved the highest test accuracy of 90.31% (macro F1-score 0.90) on an independent 196-image test set, outperforming the non-fine-tuned baseline by 15.31 points and the pure CNN-softmax variant by 4.95 points. The entire pipeline has been successfully implemented as a public web application named FACEDX using React.js with Tailwind CSS (frontend) and Flask with Gunicorn (backend), deployed on Railway with a custom domain and comprehensive error handling. This application can be utilized by the general public, dermatologists, and the cosmetic industry for more accurate and personalized skincare recommendations.

Keyword: *facial skin classification, MobileNetV2, RBF-SVM, transfer learning, web application .*

BAB I

PENDAHULUAN

1.1 Latar Belakang

Salah satu bagian tubuh yang sangat memengaruhi kesehatan dan penampilan seseorang adalah kulit wajahnya. Jenis kulit wajah yang berbeda, seperti normal, berminyak, kering, sensitif, atau kombinasi, menentukan perawatan yang tepat untuk mencegah masalah seperti pori pori besar atau jerawat. Penilaian manual oleh dokter kulit sering subjektif, memakan waktu, dan bergantung pada keahlian individu, sehingga menghasilkan diagnosis yang tidak konsisten [1].

Observasi terhadap masyarakat Indonesia menunjukkan prevalensi tinggi kondisi kulit wajah yang butuh identifikasi dini. Studi observasional pada 419 perempuan usia 20 hingga 60 tahun di Jakarta menemukan *melasma* mencapai 71% di usia 20-30 tahun, jerawat memengaruhi 10% responden pada kelompok usia yang sama [2]. Tinjauan pustaka nasional menyoroti ketidakmampuan menentukan tipe kulit sering sebabkan kesalahan pemilihan produk *skincare*, di mana survei *Beauty* 2018 menunjukkan penjualan *skincare* mencapai 31.7% dari total industri kosmetik [3].

Akses terbatas untuk konsultasi secara langsung kepada dokter kulit di luar kota-kota besar memperburuk fenomena ini. Sementara pertumbuhan industri kosmetik diprediksi mencapai 7.2% per tahun hingga 10-15 tahun mendatang [3], Situasi ini menciptakan kebutuhan akan solusi otomatis berbasis pengolahan citra untuk klasifikasi jenis kulit yang akurat, cepat, dan dapat diakses secara luas melalui perangkat digital.

Perkembangan Deep Learning, khususnya Convolutional Neural Network (CNN), mendukung klasifikasi citra kulit wajah dengan mengekstraksi fitur seperti tekstur dan warna [4], [5]. MobileNetV2, memiliki arsitektur CNN yang baik untuk perangkat berkomputasi terbatas, yang mendukung efisiensi komputasi pada aplikasi berbasis web [6]. Studi sebelumnya menunjukkan keberhasilan MobileNetV2 dalam klasifikasi penyakit kulit, menjadi dasar potensial untuk klasifikasi jenis kulit wajah [7].

Beberapa metode untuk mengklasifikasikan citra kulit wajah telah dikembangkan menggunakan pendekatan CNN. ResNet-50 mencapai akurasi 99.86% pada dataset sebanyak 1,119 citra [8]. Teachable Machine menghasilkan akurasi hingga 98-99% pada citra kulit wajah berjerawat, berminyak, dan sehat dalam eksperimen dengan dataset lebih

besar [9]. MobileNetV2 capai akurasi hingga 89% pada 350 citra jerawat [10].

Metode berbasis fitur manual masih rentan terhadap variasi kondisi eksternal seperti pencahayaan, yang dapat menurunkan akurasi klasifikasi kulit wajah [11]. CNN tanpa transfer learning mengalami penurunan performa signifikan pada dataset terbatas [12]. Oleh karena itu, penggunaan model pretrained seperti ResNet50 tetap mampu mencapai akurasi >90 % hanya dengan kurang dari 3.000 gambar dan dapat dijalankan secara real-time pada aplikasi web [13].

Klasifikasi berbasis CNN sering memerlukan dataset besar dan waktu pelatihan yang lama [14]. Untuk mengatasi masalah ini, Model seperti MobileNetV2, yang dilatih pada dataset ImageNet, meningkatkan efisiensi dan akurasi dengan data terbatas [15]. Dengan Metode hybrid ini telah berhasil digunakan untuk mengkategorikan penyakit kulit seperti kanker kulit, dan telah menunjukkan hasil yang menguntungkan [16],[17] . Penelitian ini didorong oleh terbatasnya studi klasifikasi jenis kulit menggunakan metode tersebut.

Meningkatnya kesadaran akan perawatan kulit personal, didukung oleh meluasnya akses internet, mendorong pengembangan model klasifikasi berbasis web [9]. Tujuan dari penelitian ini adalah untuk membuat model klasifikasi citra kulit wajah yang akurat dan efektif yang dapat digunakan pada platform berbasis web yang dapat diakses melalui browser pada perangkat seperti laptop, tablet, atau smartphone dengan spesifikasi standar. Model ini mendukung rekomendasi perawatan kulit secara real-time, yang relevan untuk industri kecantikan dan kesehatan kulit wajah [18].

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengembangkan model klasifikasi citra jenis kulit wajah menggunakan pendekatan hybrid transfer learning MobileNet-SVM?
2. Seberapa akurat model hybrid MobileNet-SVM dalam mengklasifikasikan jenis kulit wajah (normal, berminyak, berjerawat, kering) berdasarkan citra digital, berdasarkan metrik akurasi, presisi, recall, dan F1-score?
3. Bagaimana model klasifikasi jenis kulit wajah yang tepat dan efisien dapat diimplementasikan dalam sebuah aplikasi web yang dapat digunakan oleh masyarakat umum melalui perangkat berbasis browser dengan spesifikasi standar?

1.3 Batasan Masalah

Untuk menjaga fokus penelitian, batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian hanya mengklasifikasikan jenis kulit wajah yang terdiri dari normal, berminyak, kering, dan berjerawat berdasarkan citra digital.
2. Dataset citra yang digunakan berasal dari database publik, tanpa melibatkan akuisisi data lokal.
3. Model klasifikasi hanya menggunakan arsitektur MobileNet dengan Support Vector Machine (SVM) sebagai pengklasifikasi, tanpa membandingkan dengan arsitektur lain seperti ResNet atau VGG.
4. Penelitian tidak mencakup analisis penyakit kulit, hanya berfokus pada klasifikasi jenis kulit wajah.
5. Penelitian hanya menggunakan model transfer learning dengan MobileNet yang telah dilatih sebelumnya pada dataset ImageNet, tanpa melatih model dari awal.
6. Evaluasi model hanya dilakukan berdasarkan metrik akurasi, presisi, recall, dan F1-score, tanpa analisis performa pada perangkat keras tertentu seperti smartphone.

1.4 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dikemukakan, tujuan penelitian ini adalah sebagai berikut:

1. Mengembangkan model klasifikasi citra jenis kulit wajah (normal, berminyak, berjerawat dan kering) yang akurat melalui pendekatan hybrid transfer learning MobileNet-SVM menggunakan dataset publik.
2. Menganalisis dan memvalidasi performa model hybrid MobileNet-SVM dalam mengklasifikasikan jenis kulit wajah berdasarkan metrik evaluasi akurasi, presisi, recall, dan F1-score.
3. Mengintegrasikan model yang dikembangkan ke dalam aplikasi web yang dapat diakses publik untuk mendukung analisis kulit wajah secara otomatis dan real-time.

1.5 Manfaat Penelitian

Jika tujuan penelitian ini tercapai, maka manfaat yang dapat diperoleh adalah sebagai berikut:

1. Manfaat Teoretis: Hasil penelitian ini dapat menjadi referensi bagi penelitian lanjutan terkait pengembangan model klasifikasi berbasis deep learning yang efisien. Penelitian ini dapat memperkaya wawasan ilmiah tentang penerapan pendekatan hybrid transfer learning MobileNet-SVM dalam klasifikasi citra jenis kulit wajah, khususnya dalam bidang pengolahan citra dan kecerdasan buatan.
2. Manfaat Praktis: Model klasifikasi yang dikembangkan dapat dimanfaatkan melalui aplikasi web oleh masyarakat umum, praktisi kecantikan, atau industri kosmetik dalam menentukan jenis kulit wajah (normal, berminyak, berjerawat, kering) secara otomatis dan akurat berdasarkan citra digital. Hal ini memungkinkan pemilihan produk perawatan kulit yang lebih tepat, mengurangi ketergantungan pada penilaian manual, dan mendukung pengembangan aplikasi berbasis smartphone untuk analisis kulit wajah.

1.6 Sistematika Penulisan

Sistematika penulisan skripsi ini memuat uraian garis besar isi setiap bab yang disusun untuk memberikan gambaran menyeluruh tentang penelitian. Berikut adalah deskripsi isi masing-masing bab:

BAB I PENDAHULUAN

Bab ini terdiri dari enam subbab, yaitu latar belakang masalah yang menguraikan pentingnya klasifikasi otomatis jenis kulit wajah, keterbatasan metode manual, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, serta sistematika penulisan.

BAB II TINJAUAN PUSTAKA

Bab ini berisi tinjauan pustaka terhadap penelitian terdahulu, serta dasar teori yang digunakan, meliputi pengolahan citra digital, machine learning, deep learning, Convolutional Neural Network (CNN), arsitektur MobileNetV2, transfer learning, Support Vector Machine (SVM), dan metrik evaluasi performa model.

BAB III METODE PENELITIAN

Bab ini didalamnya terdapat penjelasan objek penelitian berupa citra jenis kulit wajah, alur penelitian yang mencakup akuisisi data, pra-pemrosesan dan augmentasi, pembuatan model hybrid MobileNetV2 dengan RBF-SVM, implementasi ke dalam aplikasi web, pengujian, serta deployment, disertai dengan alat dan bahan yang digunakan baik perangkat keras maupun perangkat lunak.

BAB IV HASIL DAN PEMBAHASAN

Bab ini merupakan tahapan yang penulis lakukan dalam mengembangkan model klasifikasi, meliputi eksplorasi dataset, pra-pemrosesan data, pelatihan dan evaluasi model hybrid, analisis kesalahan klasifikasi, pengembangan aplikasi web FACEDX, pengujian sistem, hingga proses deployment aplikasi pada domain publik <https://facedx.web.id>, dilengkapi pembahasan mendalam dan perbandingan dengan penelitian terdahulu.

BAB V PENUTUP

Bab ini berisi kesimpulan yang merangkum pencapaian tujuan penelitian serta saran yang dapat peneliti rangkum selama proses penelitian, termasuk rekomendasi pengembangan lebih lanjut untuk meningkatkan akurasi model dan penerapan sistem pada skala yang lebih luas

BAB II

TINJAUAN PUSTAKA

2.1 Studi Literatur

Studi Penelitian pertama yang relevan adalah studi oleh P. N. Srinivasu et al. (2021) yang menerapkan MobileNetV2 dan LSTM untuk klasifikasi penyakit kulit menggunakan dataset publik, termasuk dari Kaggle [4]. Penelitian ini mencapai akurasi 85% dalam mendeteksi berbagai jenis penyakit kulit, dengan keunggulan efisiensi MobileNetV2. Meskipun fokusnya pada penyakit kulit secara umum dan bukan jenis kulit wajah, penggunaan MobileNet yang sama dengan penelitian ini menunjukkan relevansi dasar. Namun, tidak ada integrasi SVM, menjadi celah utama penelitian ini.

Kedua, penelitian oleh D. Anggriandi, E. Utami, dan D. Ariatmanto (2023) melakukan analisis perbandingan antara CNN dan CNN-SVM untuk klasifikasi penyakit kulit manusia [18]. Studi ini menggunakan dataset kulit dari sumber terbuka dan menunjukkan bahwa CNN-SVM meningkatkan akurasi hingga 5% dibandingkan CNN saja. Tema datasetnya mirip dengan konteks kulit secara umum, tetapi tidak spesifik pada jenis kulit wajah. Penggunaan SVM yang sama memberikan dasar untuk pendekatan hybrid dalam penelitian ini, dengan penyesuaian pada transfer learning MobileNet.

Ketiga, penelitian oleh R. Yohannes dan M. E. Al Rivan (2022) mengeksplorasi klasifikasi kanker kulit menggunakan kombinasi CNN dan SVM [14]. Penelitian ini menggunakan dataset citra kulit dari sumber publik dan mencapai akurasi 90% dengan pendekatan hybrid. Meskipun tema dataset berbeda, penggunaan algoritma SVM yang sama dengan penelitian ini menunjukkan potensi pendekatan hybrid. Penelitian ini tidak menggunakan transfer learning atau MobileNet, sehingga penelitian ini akan menyesuaikan dengan konteks jenis kulit wajah.

Keempat, studi oleh R. Dandu, M. Vinayaka Murthy, dan Y. B. Ravi Kumar (2023) fokus pada deteksi dan klasifikasi kanker kulit (*melanoma*) menggunakan transfer learning dan klasifikasi hybrid [19]. Penelitian ini memanfaatkan model pre-trained dan SVM pada dataset kulit, mencapai akurasi tinggi. Meskipun tema datasetnya berbeda, penggunaan transfer learning dan SVM yang serupa dengan pendekatan penelitian ini menunjukkan relevansi. Penelitian ini tidak menggunakan MobileNet atau fokus pada jenis kulit wajah, sehingga penelitian ini akan menyesuaikan dengan konteks spesifiknya.

Kelima, penelitian oleh A. Zakiah, R. Patmasari, dan S. Saidah (2021) fokus pada klasifikasi jenis kulit wajah menggunakan metode CNN [1]. Studi ini menggunakan dataset citra wajah yang relevan dengan tema penelitian ini, yaitu identifikasi jenis kulit seperti normal, berminyak, dan kering. Mereka mencapai akurasi sekitar 85% dengan arsitektur CNN standar. Penelitian ini menunjukkan potensi CNN dalam analisis kulit wajah, tetapi tidak memanfaatkan transfer learning atau kombinasi dengan SVM, yang menjadi keunggulan pendekatan yang diusulkan dalam skripsi ini.

Keenam, studi oleh D. Marya et al. (2025) mengembangkan sistem klasifikasi jenis kulit wajah berbasis CNN MobileNetV2 untuk smartphone [6]. Penelitian ini menggunakan dataset yang dikumpulkan dari berbagai sumber publik, termasuk platform seperti Kaggle, yang serupa dengan dataset dalam penelitian ini. Hasilnya menunjukkan akurasi 87.5% dalam mengklasifikasikan jenis kulit wajah, dengan fokus pada efisiensi komputasi untuk perangkat bergerak. Namun, penelitian ini tidak mengintegrasikan SVM atau pendekatan hybrid, sehingga menjadi celah yang akan diisi oleh penelitian ini dengan pendekatan MobileNet-SVM.

Ketujuh, Penelitian oleh Abd. Ghofur et al. (2025) mengembangkan model klasifikasi untuk gambar kulit wajah berdasarkan Teachable Machine untuk kondisi kulit berjerawat, berminyak, dan sehat [9]. Penelitian ini relevan karena menggunakan MobileNetV2 untuk klasifikasi kulit dengan efisiensi pada sumber daya terbatas yang serupa dengan fokus penelitian ini. Tidak ada integrasi dengan SVM atau bentuk model hibrida lainnya, ini akan menjadi celah yang akan diisi dalam penelitian ini.

Kedelapan, penelitian oleh G. S. Sylvagno dan T. H. Rochadiani (2025) membangun sistem rekomendasi skincare berdasarkan klasifikasi jenis kulit wajah dengan integrasi data weather real-time menggunakan ResNet50 dan Decision Tree [13]. Penelitian ini menunjukkan hubungan antara penggunaan CNN untuk klasifikasi jenis kulit wajah pada dataset publik seperti Kaggle. Namun, penelitian ini akan menyesuaikan pendekatan hybrid untuk meningkatkan efisiensi pada perangkat terbatas tanpa komponen cuaca karena fokus utamanya adalah rekomendasi produk dengan integrasi cuaca daripada hybrid MobileNet-SVM.

Keaslian penelitian ini dapat dilihat pada Tabel 2.1, yang membandingkan penelitian ini dengan penelitian terdahulu berdasarkan beberapa aspek.

Tabel 2.1. Keaslian Penelitian

No	Judul penelitian	Nama Penulis	Tahun Publikasi	Hasil Penelitian	Perbandingan Penelitian
1	Classification of Skin Disease Using Deep Learning Neural Networks with MobileNet V2 and LSTM	P. N. Srinivasu, J. G. SivaSai, M. F. Ijaz, A. K. Bhoi, W. Kim, dan J. J. Kang,	2021	Akurasi 85% klasifikasi penyakit kulit	Fokus penyakit kulit, pakai LSTM, tanpa SVM
2	Comparative Analysis of CNN and CNN-SVM Methods for Classification Types of Human Skin Disease	D. Anggriandi, E. Utami, dan D. Ariatmanto	2023	CNN-SVM naik 5% akurasi vs CNN saja pada penyakit kulit	Fokus penyakit kulit, tanpa MobileNet
3	Klasifikasi Jenis Kanker Kulit Menggunakan CNN-SVM	R. Yohannes dan M. E. Al Rivan	2022	Akurasi 90% klasifikasi kanker kulit	Fokus kanker kulit, tanpa transfer learning MobileNet
4	Transfer Learning for Segmentation with Hybrid Classification to Detect Melanoma Skin Cancer	R. Dandu, M. Vinayaka Murthy, dan Y. B. Ravi Kumar	2023	Akurasi 88% deteksi melanoma dengan transfer learning dan SVM	Fokus kanker kulit, tanpa MobileNet
5	Klasifikasi Jenis Kulit Wajah Menggunakan Metode Convolutional Neural Network	Zakiah, R. Patmasari, dan S. Saidah	2021	Akurasi 85% klasifikasi jenis kulit wajah	CNN murni, tanpa transfer learning & SVM

Tabel 2.1. Lanjutan

No	Judul penelitian	Nama Penulis	Tahun Publikasi	Hasil Penelitian	Perbandingan Penelitian
6	Development of an Optimized Facial Skin Type Classification System using CNN MobileNetV2 for Real-Time Smartphone Applications	D. Marya, C. Mustika Sari Ramadhani, dan R. Ardiansyah	2025	Akurasi 87.5% klasifikasi jenis kulit wajah di smartphone	Menggunakan MobileNetV2, tanpa SVM/hybrid
7	JUSTIFY: Klasifikasi Image Kulit Wajah Berjerawat, Berminyak dan Kulit Sehat Menggunakan Teachable Machine Learning	A. Ghofur, A. Apriliana, R. A. Ningsih, dan N. D. Kamelia	2025	Akurasi 94 sampai 99% klasifikasi kulit wajah MobileNetV2	MobileNetV2 efisien yaitu Teachable, tanpa SVM
8	Skincare Recommendation System Based on Facial Skin Type with Real-Time Weather Integration	Gabrielle Sheila Sylvagno dan T. H. Rochadiani	2025	Akurasi rata-rata 90.94% klasifikasi jenis kulit wajah dan rekomendasi	Menggunakan ResNet50 dengan Decision Tree dan weather, bukan hybrid MobileNet-SVM

2.2 Dasar Teori

2.2.1 Machine Learning

Machine learning adalah cabang kecerdasan buatan yang memungkinkan sistem belajar dari data tanpa pemrograman eksplisit. Algoritma machine learning mengenali pola untuk melakukan prediksi atau klasifikasi. P. N. Srinivasu, J. G. SivaSai, M. F. Ijaz, A. K. Bhoi, W. Kim, and J. J. Kang (2021) melakukan penelitian berjudul *Classification of Skin Disease Using Deep Learning Neural Networks with MobileNet V2 and LSTM*. Tujuan dari penelitian ini adalah mengklasifikasikan penyakit kulit menggunakan deep learning. Dari hasil penelitian disimpulkan bahwa model MobileNetV2 dan LSTM mencapai akurasi lebih dari 85% pada dataset HAM10000, menunjukkan efektivitasnya untuk klasifikasi penyakit kulit dari citra kulit [4].

2.2.2 Klasifikasi

Klasifikasi adalah proses *machine learning* untuk memetakan data ke kategori tertentu berdasarkan fitur yang dipelajari. M. S. Ali, M. S. Miah, J. Haque, M. M. Rahman, and M. K. Islam (2021) melakukan penelitian berjudul *An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models*. Tujuan penelitian ini meningkatkan akurasi klasifikasi kanker kulit. Dari hasil penelitian disimpulkan bahwa model CNN dengan transfer learning mencapai akurasi 94,59% pada dataset kulit [5]. Mendukung penggunaan klasifikasi multi-class untuk jenis kulit wajah dalam penelitian ini

2.2.3 Jenis Kulit Wajah

Jenis kulit wajah didefinisikan berdasarkan karakteristik seperti produksi *sebum*, *hidrasi*, dan tekstur. Zakiah, R. Patmasari, and S. Saidah (2021) melakukan penelitian berjudul *Klasifikasi Jenis Kulit Wajah Menggunakan Metode Convolutional Neural Network*. Tujuan penelitian ini adalah mengklasifikasikan jenis kulit wajah berdasarkan fitur visual. Dari hasil penelitian disimpulkan bahwa CNN dapat mengklasifikasikan jenis kulit (normal, berminyak, kering) dengan akurasi tinggi menggunakan citra, mendukung analisis dalam penelitian ini [1].

2.2.4 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah jaringan saraf tiruan yang dirancang untuk memproses data berstruktur seperti citra. MobileNetV2 merupakan arsitektur CNN yang efisien dengan penggunaan depthwise separable convolution dan inverted residual block, sehingga cocok untuk aplikasi real-time pada perangkat dengan sumber daya terbatas. D. Marya, C. Mustika Sari Ramadhani, dan R. Ardiansyah (2025) melakukan penelitian *pengembangan sistem klasifikasi jenis kulit wajah yang dioptimalkan menggunakan CNN MobileNetV2* untuk aplikasi smartphone real-time. Tujuan penelitian ini adalah mengklasifikasikan jenis kulit wajah secara akurat dan efisien. Hasil penelitian menunjukkan bahwa MobileNetV2 efektif untuk ekstraksi fitur dan klasifikasi citra kulit wajah, mendukung pendekatan yang digunakan dalam penelitian ini [6].

- a. Operasional Konvolusi: Operasi ini menghasilkan feature map dengan kernel untuk mengekstraksi fitur lokal seperti tepi dan tekstur.

Rumus Konvolusi:


$$f(x, y) = \sum_{i=-k/2}^{k/2} \sum_{j=-k/2}^{k/2} I(x + i, y + j) \cdot K(i, j) + b \quad (1)$$

- b. Jumlah Parameter: Jumlah parameter menunjukkan kompleksitas lapisan konvolusi berdasarkan ukuran kernel dan saluran. MobileNetV2 mengurangi jumlah parameter secara signifikan melalui depthwise separable convolution

Rumus Jumlah Parameter:

$$Parameters = (k_h \times k_w \times c_{in} \times c_{out}) + c_{out} \quad (2)$$

Pada Gambar 2.1, proses CNN divisualisasikan dengan alur tiga tahap utama dalam Inverted Residual Block pada MobileNetV2:



Gambar 2.1 Proses CNN pada Inverted Residual Block.

- 1) Perluasan Dimensi (*Expand*): Input awal diproses menggunakan konvolusi untuk memperluas dimensi data, ditunjukkan dengan kotak. Bertujuan untuk memperkaya jumlah fitur yang tersedia untuk diproses pada tahap berikutnya.
- 2) Depthwise Convolution: Data hasil perluasan diproses menggunakan *Depthwise Convolution*, yang memproses setiap kanal secara independen. Bertujuan untuk mengekstraksi pola lokal dari data tanpa menambah jumlah parameter yang signifikan.
- 3) Reduksi Dimensi (*Compress*): Hasil dari Depthwise Convolution dikembalikan ke dimensi semula menggunakan konvolusi. Proses ini bertujuan untuk mengompresi data sambil mempertahankan informasi penting.
- 4) Sebagai tambahan, sambungan residual menghubungkan input awal langsung ke output akhir blok, memastikan informasi penting tidak hilang selama pemrosesan.

2.2.5 MobileNet

MobileNet adalah arsitektur CNN ringan yang dioptimalkan untuk efisiensi komputasi, cocok untuk perangkat dengan sumber daya terbatas. D. Marya, C. Mustika Sari Ramadhani, and R. Ardiansyah (2025) melakukan penelitian berjudul *Development of an Optimized Facial Skin Type Classification System using CNN MobileNetV2 for Real-Time Smartphone Applications*. Tujuan dari penelitian ini adalah mengembangkan sistem klasifikasi jenis kulit wajah berbasis MobileNetV2. Dari hasil penelitian disimpulkan bahwa MobileNetV2 efektif untuk aplikasi real-time dengan dataset kecil, mendukung penelitian ini [6]. Rumus berikut digunakan untuk menghitung efisiensi komputasi.

a. Kompleksitas depthwise separable convolution:

Depthwise separable convolution mengurangi jumlah operasi komputasi secara signifikan dibandingkan konvolusi standar, yang menjadi dasar efisiensi MobileNetV2 [6].

Rumus perbandingan kompleksitas :

$$\frac{1}{N} + \frac{1}{D_k^2} \quad (3)$$

2.2.6 Transfer Learning

Transfer learning adalah teknik machine learning yang menggunakan model pre-trained pada dataset besar, untuk tugas spesifik dengan dataset kecil, mengurangi waktu pelatihan dan meningkatkan akurasi. H. E. Kim, A. Cosa-Linan, N. Santhanam, M. Jannesari, M. E. Maros, and T. Ganslandt (2022) melakukan penelitian berjudul *Transfer learning for medical image classification: a literature review*. Tujuan dari penelitian ini adalah mengevaluasi transfer learning pada citra medis. Dari hasil penelitian disimpulkan bahwa transfer learning efektif meningkatkan performa klasifikasi citra medis meskipun data terbatas, dengan rekomendasi feature extractor untuk efisiensi komputasi [12].

2.2.7 Support Vector Machine (SVM)

Support Vector Machine (SVM) adalah algoritma supervised learning yang mencari hyperplane optimal untuk memisahkan kelas data. R. Yohannes and M. E. Al Rivan (2022) melakukan penelitian berjudul *Klasifikasi Jenis Kanker Kulit Menggunakan CNN-SVM*. Tujuan dari penelitian ini adalah mengklasifikasikan kanker kulit dengan kombinasi CNN dan SVM. Dari hasil penelitian disimpulkan bahwa CNN-SVM meningkatkan akurasi hingga 90%, mendukung pendekatan hybrid dalam penelitian ini [14]. Rumus berikut digunakan untuk mendefinisikan hyperplane dan margin dalam SVM.

- a. Hyperplane: Rumus ini menunjukkan persamaan bidang pemisah antar kelas.

Rumus Hyperplane:

$$w^T x + b = 0 \quad (4)$$

- b. Fungsi Keputusan: Rumus ini menentukan kelas berdasarkan posisi data terhadap hyperplane.

Rumus Fungsi Keputusan:

$$y = \text{sign}(w^T x + b) \quad (5)$$

- c. Margin Maksimum: Rumus ini menghitung jarak margin maksimum antara hyperplane dan data.

Rumus Margin:

$$\frac{2}{|w|} \quad (6)$$

2.2.8 Metrik Evaluasi

Metrik evaluasi seperti akurasi, presisi, recall, dan F1-score mengukur performa model klasifikasi. D. Anggriandi, E. Utami, and D. Ariatmanto (2023) melakukan penelitian berjudul *Comparative Analysis of CNN and CNN-SVM Methods For Classification Types of Human Skin Disease*. Tujuan dari penelitian ini adalah membandingkan performa CNN dan CNN-SVM. Dari hasil penelitian disimpulkan bahwa metrik akurasi, presisi, recall, dan F1-score efektif untuk mengevaluasi dan membandingkan performa model pada tugas klasifikasi citra kulit [18]. Berikut adalah rumus standar yang digunakan untuk menghitung metrik-metrik tersebut.

- a. Akurasi (Accuracy): Akurasi mengukur proporsi prediksi yang benar dari seluruh jumlah data yang diuji. Ini adalah metrik yang umum digunakan untuk menilai seberapa baik model dalam mengklasifikasikan data secara keseluruhan.

Rumus Akurasi:

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN} \quad (7)$$

- b. Presisi (Precision): Presisi mengukur proporsi prediksi positif yang benar. Dalam kasus klasifikasi jenis kulit wajah, presisi menunjukkan seberapa banyak jenis kulit yang diprediksi benar-benar sesuai dengan kategori tersebut.

Rumus Presisi:

$$\text{Presisi} = \frac{TP}{TP + FP} \quad (8)$$

- c. Recall: Mengukur proporsi kasus positif yang berhasil dikenali oleh model.

Rumus Recall:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (9)$$

- d. F1-Score: F1-Score adalah rata-rata harmonik dari presisi dan recall, digunakan untuk mengevaluasi performa model pada data yang tidak seimbang.

Rumus F1-Score:

$$F1\text{-Score} = 2 \cdot \frac{\text{Presisi} \cdot \text{Recall}}{\text{Presisi} + \text{Recall}} \quad (10)$$

BAB III


METODE PENELITIAN

3.1 Objek Penelitian

Objek yang diteliti dalam penelitian ini adalah citra jenis kulit wajah, dengan tujuan mengembangkan model klasifikasi otomatis untuk mengenali berbagai jenis kulit wajah. Citra yang digunakan mencerminkan karakteristik kulit wajah yang bervariasi dan diperoleh dari Roboflow. Studi ini secara eksplisit berfokus pada analisis citra detail sebagai elemen inti dari keseluruhan proses penelitian. Oleh karena itu, keterlibatan langsung individu, kelompok, atau organisasi eksternal dihindari. Ini berarti tidak ada interaksi fisik, wawancara, atau pengumpulan data primer dengan partisipan studi yang dilakukan selama keseluruhan studi. Lingkungan penelitian sepenuhnya virtual dan digital. Semua fase analisis, pemrosesan data, pelatihan model, dan evaluasi hasil dilakukan pada komputer pribadi atau server cloud dengan koneksi internet yang stabil ke kumpulan data yang diakses secara terpisah melalui platform seperti Roboflow. Hal ini memungkinkan fleksibilitas yang tinggi terkait waktu, lokasi, dan sumber daya komputasi tanpa batasan geografis. Dalam penelitian ini, terdapat empat jenis kulit wajah yang digunakan sebagai objek klasifikasi, yaitu kulit berminyak (*oily*), kulit berjerawat (*acne*) kulit kering (*dry*), dan kulit normal. Jenis-jenis tersebut dipilih berdasarkan representasi umum dari kondisi kulit wajah yang sering menjadi perhatian dalam analisis dermatologis dan teknologi pengenalan citra.

3.2 Alur Penelitian

Penelitian ini dilakukan melalui alur penelitian terstruktur, yang diilustrasikan pada Gambar 3.1 Alur Penelitian. Alur ini mencakup proses pengembangan model klasifikasi berbasis pembelajaran mendalam dan implementasi sistem berbasis web.



Gambar 3.1 Alur Penelitian

3.2.1 Identifikasi Masalah

Penelitian dimulai dengan mengidentifikasi masalah melalui tinjauan latar belakang dan data survei yang menunjukkan mayoritas masyarakat kesulitan menentukan jenis kulit wajah secara akurat. Selanjutnya dilakukan analisis kesenjangan antara metode manual yang subjektif dengan kebutuhan solusi otomatis berbasis citra, sehingga dirumuskan tujuan penelitian yaitu membangun sistem klasifikasi jenis kulit wajah menggunakan pendekatan hybrid MobileNetV2-SVM yang dapat diakses melalui web.

3.2.2 Studi Literatur

Tahap ini dilakukan dengan mencari dan mengumpulkan jurnal serta artikel ilmiah terkait klasifikasi kulit wajah dan penyakit kulit menggunakan CNN, MobileNetV2, serta kombinasi hybrid dengan SVM. Setiap referensi dibaca, dirangkum, dan dibandingkan untuk menemukan celah penelitian. Hasil studi menunjukkan belum adanya penerapan MobileNetV2 sebagai feature extractor yang digabung SVM-RBF khusus untuk empat jenis kulit wajah dan diimplementasikan ke aplikasi web, sehingga menjadi dasar pemilihan metode dalam penelitian ini.

3.2.3 Akusisi Data

Sebelum memulai pengolahan data, proses akusisi data diperlukan. Tujuan akusisi data ini adalah untuk mengumpulkan gambar jenis kulit wajah, yang akan digunakan sebagai dasar pembangunan model. Dataset sebanyak dua ribu gambar digunakan dalam penelitian ini, yang dibagi menjadi empat kelas utama kulit: kulit berjerawat (*acne*), kulit berminyak (*oily*), kulit kering (*dry*), dan kulit normal. Data ini diperoleh dari Roboflow, yang dapat mengakses kumpulan gambar berkualitas tinggi. Dataset diunduh dalam format terkompresi sebelum diekstraksi ke dalam struktur folder yang terorganisir untuk kemudahan pengelolaan. Untuk memastikan data konsisten, distribusi kelas dan resolusi gambar (minimal 224 x 224 piksel) diperiksa untuk memastikan bahwa model dapat belajar dengan baik dari representasi yang merata. Diharapkan model dapat menangkap berbagai karakteristik kulit wajah secara menyeluruh dengan adanya dataset yang cukup besar ini.

3.2.4 Pra-pemrosesan Data

Sebelum gambar diolah lebih lanjut, proses pra-pemrosesan data dilakukan untuk meningkatkan kualitas data agar siap digunakan dalam pelatihan model. Dalam pengolahan gambar, augmentasi data adalah teknik yang sangat penting, terutama ketika menggunakan deep learning untuk mengklasifikasikan jenis kulit wajah. Terlepas dari kenyataan bahwa dataset yang digunakan terdiri dari 2000 gambar, ada beberapa alasan kuat untuk menggunakan peningkatan data. Pertama, peningkatan variabilitas data memungkinkan penggunaan rotasi, flip, dan perubahan skala untuk menghasilkan variasi baru pada gambar yang ada, yang memungkinkan model untuk memperoleh perspektif yang lebih beragam. Kedua, mengurangi overfitting: meskipun jumlah data cukup, model deep learning seperti MobileNetV2 sering mengalami overfitting karena kompleksitas

fitur, dan augmentasi secara efektif memperluas dataset. Ketiga, dengan mengoptimalkan penggunaan data, augmentasi memungkinkan penggunaan hingga dua ribu gambar tanpa perlu mengumpulkan lebih banyak data yang memakan waktu. Terakhir, meningkatkan akurasi klasifikasi, penelitian sebelumnya menunjukkan bahwa, dengan membantu model mengenali fitur penting dari setiap kelas kulit, augmentasi dapat meningkatkan akurasi klasifikasi. Pada titik ini, augmentasi dilakukan dengan menggunakan library ImageDataGenerator dari TensorFlow. Proses dimulai dengan rescaling piksel (dibagi 255.0 untuk menormalisasi ke rentang 0-1), mengubah variasi seperti rotasi 40 derajat, pergeseran lebar dan tinggi 20%, shear dengan rentang 0.2, zoom dengan rentang 0.2, dan flip horizontal dengan mode pengisian terdekat untuk mengisi piksel kosong. Selain itu, gambar diresize menjadi 224 x 224 piksel menggunakan OpenCV, dan untuk memastikan kualitas data, visualisasi digunakan dengan Matplotlib.

3.2.5 Pembuatan Model

Setelah data diproses, proses pembuatan model dilakukan untuk menghasilkan sistem klasifikasi hybrid berbasis citra kulit wajah yang akurat dan efisien secara komputasi. Proses ini dimulai dengan memuat arsitektur MobileNetV2 yang telah dilatih sebelumnya pada dataset ImageNet menggunakan framework TensorFlow tanpa lapisan klasifikasi teratas. Untuk menyesuaikan ekstraksi fitur dengan karakteristik domain citra kulit wajah, dilakukan fine-tuning mendalam pada 80 lapisan terakhir model tersebut; lapisan sebelumnya tetap dibekukan untuk mempertahankan fitur generik dari ImageNet. Selama fine-tuning, ditambahkan kepala klasifikasi sementara yang terdiri dari GlobalAveragePooling2D, beberapa lapisan Dropout untuk regularisasi, Dense layer dengan aktivasi ReLU disertai BatchNormalization, serta lapisan output dengan softmax sesuai jumlah kelas. Model dikompilasi menggunakan optimizer Adam dengan learning rate awal 3×10^{-4} , fungsi loss categorical crossentropy, dan dilatih selama maksimal 100 epoch dengan ukuran batch 32, dilengkapi mekanisme EarlyStopping serta callback lainnya untuk mencegah overfitting. Setelah fine-tuning selesai, kepala klasifikasi sementara dibuang, dan vektor fitur 1280-dimensi diekstrak dari layer GlobalAveragePooling2D untuk seluruh dataset. Fitur tersebut kemudian dinormalisasi menggunakan StandardScaler dan digunakan untuk melatih Support Vector Machine (SVM) dengan kernel Radial Basis Function (RBF) melalui library scikit-learn. Pelatihan SVM dilakukan pada dataset pelatihan berisi 1401 citra, dengan hyperparameter C dan

gamma dioptimalkan menggunakan GridSearchCV dengan validasi silang 5-fold. Kombinasi MobileNetV2 sebagai feature extractor yang telah di-fine-tune secara mendalam dengan SVM sebagai classifier akhir memungkinkan komputasi yang lebih efisien sekaligus akurasi tinggi, terutama pada dataset dengan variasi yang telah ditingkatkan melalui augmentasi data.

3.2.6 Evaluasi dan Optimasi

Setelah model hybrid selesai dibuat, tahap evaluasi dan optimasi dilakukan untuk memverifikasi kinerja serta memastikan kemampuan generalisasi pada data baru. Evaluasi utama menggunakan 20% data validasi (403 citra) dan data pengujian independen (196 citra) yang tidak pernah terlihat selama pelatihan maupun fine-tuning, dengan metrik akurasi keseluruhan, precision, recall, F1-score per kelas, serta analisis matriks confusion untuk mengidentifikasi pola kesalahan klasifikasi. Optimasi hyperparameter dilakukan pada tahap fine-tuning MobileNetV2 dengan learning rate awal 3×10^{-4} yang disesuaikan secara otomatis melalui ReduceLROnPlateau, serta EarlyStopping untuk mencegah overfitting; sementara pada tahap SVM, GridSearchCV digunakan untuk menemukan kombinasi C dan gamma optimal. Hasil evaluasi menunjukkan model hybrid mencapai akurasi tertinggi 90,31% pada data pengujian independen, dengan peningkatan signifikan dibandingkan baseline, dan kesalahan klasifikasi terutama pada kelas normal dan dry yang berhasil diminimalkan berkat kemampuan RBF-SVM dalam menangani batas non-linear. Proses ini krusial untuk memastikan model robust, memiliki performa tinggi di atas 80%, dan siap diterapkan pada citra kulit wajah baru, didukung augmentasi data yang meningkatkan variasi dataset.

3.2.7 Pembuatan UI/UX

Tahap pembuatan UI/UX diperlukan sebelum integrasi ke aplikasi web. Tahap ini bertujuan untuk membuat antarmuka pengguna yang intuitif. Proses dimulai dengan desain tata letak menggunakan Figma. Ini mencakup area hasil prediksi, navigasi sederhana, dan tombol pengunggahan citra. Untuk menguji desain ini, prototipe interaktif digunakan untuk mengumpulkan komentar dari pengguna awal, beberapa mengusulkan penambahan tooltip ke panduan. Pastikan antarmuka mendukung fungsi klasifikasi dengan efisien karena UI/UX yang baik meningkatkan pengalaman pengguna.

3.2.8 Integrasi Frontend dan Backend Web

Untuk membangun aplikasi web yang berfungsi, tahap integrasi frontend dan backend web dilakukan setelah pengembangan komponen frontend dimulai. Frontend dibuat menggunakan React dan Tailwind CSS untuk menyediakan antarmuka interaktif yang responsif dan efektif, termasuk form pengunggahan gambar menggunakan komponen seperti ImageUpload.js. Backend dibangun dengan Flask, yang memuat model MobileNet-SVM yang telah dilatih sebelumnya dan menyediakan API (endpoint/predict) untuk menangani permintaan gambar dari frontend dan mengembalikan prediksi dalam format JSON. Integrasi ini memungkinkan komunikasi yang lebih baik antara frontend dan backend.

3.2.9 Pengujian Lokal

Setelah integrasi selesai, tahap pengujian lokal diperlukan untuk memastikan bahwa aplikasi berfungsi dengan baik secara keseluruhan sebelum deployment . Pengujian ini meliputi pengujian fungsional dengan mengunggah sekitar 50 gambar sampel dari data uji (total 196 gambar) agar prediksi kelas kulit wajah dapat berjalan dengan benar dan lancar, pengujian responsivitas antarmuka pada perangkat desktop, tablet, serta mobile, dan pengujian penanganan kesalahan untuk kondisi umum seperti wajah tidak terdeteksi, file bukan gambar, ukuran file berlebih, serta gambar resolusi rendah atau korup. Pengujian ini bertujuan mengidentifikasi dan memperbaiki potensi masalah sebelum aplikasi diterapkan. Kinerja prediksi akan diamati secara kualitatif melalui pengujian manual dengan target proses yang cepat dan nyaman bagi pengguna.

3.2.10 Deployment

Setelah aplikasi berhasil melewati pengujian lokal, fase deployment pun dilakukan. Repositori terpisah dibuat untuk frontend dan backend untuk menyederhanakan pemeliharaan dan penskalaan di masa mendatang. Kedua bagian aplikasi disebarkan pada platform Railway.app: frontend React.js , sedangkan backend Flask, bersama dengan model (.h5), scaler, dan label encoder, disebarkan sebagai layanan dinamis. Environment variable diatur sesuai kebutuhan, domain khusus diaktifkan, dan pengujian akhir dilakukan melalui URL publik untuk memastikan semua fungsi bekerja dengan benar dan proses prediksi berjalan lancar. Setelah semua komponen berfungsi dengan baik, aplikasi siap diakses oleh pengguna akhir langsung dari browser tanpa instalasi tambahan apa pun.

3.2.11 Kesimpulan dan Saran

Tahap terakhir adalah menyusun kesimpulan bahwa seluruh rangkaian proses dari akuisisi data, preprocessing, pembuatan model hybrid MobileNetV2-SVM, hingga deployment berhasil menghasilkan aplikasi web klasifikasi jenis kulit wajah dengan akurasi di atas 90%. Seluruh tujuan penelitian tercapai dan model dapat diakses secara publik. Untuk pengembangan selanjutnya disarankan menambah kelas kulit sensitif, mengintegrasikan kamera smartphone secara langsung, menggunakan model yang lebih ringan seperti EfficientNet-Lite, melakukan validasi klinis bersama dokter kulit, serta menambahkan fitur rekomendasi produk skincare secara otomatis.

3.3 Alat dan Bahan

3.3.1 Data Penelitian

Data penelitian dalam penelitian ini terdiri dari kumpulan citra jenis kulit wajah yang digunakan sebagai dasar untuk mengembangkan dan menguji model klasifikasi. Dataset yang dimanfaatkan berjumlah 2000 citra, yang mencakup empat kelas utama: kulit berjerawat (*acne*), kulit berminyak (*oily*), kulit kering (*dry*), dan kulit normal (*normal*). Data ini diperoleh dari platform Roboflow, sebuah layanan daring yang menyediakan dataset citra berkualitas tinggi yang dikurasi untuk keperluan penelitian berbasis machine learning dan computer vision. Proses pengumpulan data dimulai dengan mengakses situs web Roboflow, melakukan registrasi akun, dan mengunduh dataset dalam format terkompresi (*ZIP*) yang kemudian diekstrak ke dalam struktur folder terorganisir (*train, test, validation*). Data diproses lebih lanjut di lingkungan Kaggle Code untuk analisis awal dan pelatihan model, dengan memastikan resolusi citra konsisten (minimal 224x224 piksel) dan distribusi kelas yang memadai untuk mendukung pendekatan hybrid MobileNet-SVM.

3.3.2 Instrumen Penelitian

Alat yang digunakan pada penelitian ini terdiri dari dua perangkat, yaitu perangkat keras dan perangkat lunak. Perangkat keras yang dipakai berupa laptop MSI Katana dengan spesifikasi Prosesor Intel Core i7 generasi ke-12, Kartu Grafis GeForce RTX 3070 Ti Laptop GPU 8GB GDDR6, dan RAM 16 GB, dengan menggunakan Sistem Operasi Windows 11 Home. Laptop ini digunakan sebagai perangkat utama untuk pengolahan data di Kaggle Code, pelatihan model MobileNet-SVM, pengembangan aplikasi web

dengan Flask dan React JS, serta deployment. Adapun perangkat lunak yang digunakan antara lain sebagai berikut:

- a. Python, sebagai bahasa pemrograman utama untuk mengembangkan model deep learning MobileNet-SVM dan analisis data, dengan versi 3.10 untuk kompatibilitas optimal dengan library terkait.
- b. Modul OS, modul Python untuk berinteraksi dengan sistem operasi, seperti mengelola file dan direktori dalam proses pengolahan data di Kaggle Code. Modul ini mendukung tahap preprocessing data dengan mendefinisikan path dataset, yang sangat penting untuk efisiensi workflow.
- c. TensorFlow, framework open-source untuk membangun dan melatih model MobileNet dengan dukungan GPU, dengan versi 2.10.0. Versi ini sesuai untuk mendukung percepatan GPU pada RTX 3070 Ti dan proses pelatihan.
- d. Keras, API tingkat tinggi yang berjalan di atas TensorFlow, memudahkan pembuatan dan pelatihan model neural network, terutama untuk augmentasi data dengan ImageDataGenerator. Penggunaan Keras sangat sesuai dengan tahap preprocessing dan pelatihan model yang dijelaskan sebelumnya.
- e. scikit-learn, pustaka Python untuk mengimplementasikan SVM dan menghitung metrik evaluasi seperti akurasi dan confusion matrix, dengan versi 1.2.2, versi ini lebih relevan untuk tahap evaluasi dan optimasi.
- f. Matplotlib, pustaka visualisasi data untuk membuat grafik performa model, seperti plot akurasi vs. epoch, dengan tampilan yang informatif. Penggunaan Matplotlib sangat sesuai dengan tahap evaluasi untuk menganalisis hasil pelatihan model.
- g. NumPy, pustaka fundamental untuk komputasi numerik dan manipulasi array, dengan versi 1.23.5.
- h. Seaborn, pustaka visualisasi data yang dibangun di atas Matplotlib, digunakan untuk membuat grafik statistik seperti confusion matrix. Penggunaan Seaborn sangat relevan untuk analisis performa model dalam tahap pengujian.
- i. Figma, alat desain antarmuka pengguna (UI) yang digunakan untuk merancang tampilan aplikasi web yang intuitif, dengan akses berbasis cloud.
- j. Visual Studio Code, editor kode sumber untuk menulis, mengembangkan, dan mendeploy aplikasi web dengan frontend React dan backend Flask, dilengkapi ekstensi untuk debugging dan pengoptimalan kode.

- k. Kaggle Code, platform daring untuk mengolah dataset Roboflow, menjalankan kode Python untuk pelatihan model, dan memanfaatkan sumber daya komputasi berbasis cloud.
- l. React, framework JavaScript untuk mengembangkan frontend aplikasi web, menyediakan antarmuka interaktif untuk pengunggahan citra dan tampilan hasil. Penggunaan React sangat sesuai dengan tahap implementasi model ke web, sesuai dengan kode ImageUpload.js.
- m. Flask, framework web ringan untuk mengembangkan backend, mengintegrasikan model MobileNet-SVM ke API, dan mendukung deployment. Penggunaan Flask sangat relevan untuk tahap implementasi dan deployment, sesuai dengan kode endpoint /predict.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Akuisisi dan Eksplorasi Dataset

4.1.1 Sumber dan Strukt Dataset

Dataset citra jenis kulit wajah yang digunakan dalam penelitian ini diperoleh dari platform Roboflow, sebuah repositori publik yang menyediakan dataset berkualitas tinggi untuk keperluan penelitian computer vision. Dataset yang diunduh memiliki total 2.000 citra wajah yang telah diberi anotasi dan diklasifikasikan ke dalam empat kelas utama, yaitu berjerawat (*acne*), kering (*dry*), normal, dan berminyak (*oily*).

Setelah diunduh dalam format *ZIP*, dataset diimpor ke dalam lingkungan Kaggle Notebook dan diekstrak ke dalam direktori utama `/kaggle/input/facialskindtype/kulitwajah`. Struktur folder dataset telah terbagi menjadi tiga sub-direktori standar, yaitu:

- a. *train* : berisi citra untuk pelatihan model
- b. *valid* : berisi citra untuk validasi selama pelatihan
- c. *test* : berisi citra untuk pengujian akhir model

Pembagian ini memungkinkan penerapan metodologi stratified split yang menjaga proporsi kelas yang hampir seimbang pada setiap subset.

4.1.2 Distribusi Kelas


Distribusi jumlah citra pada masing-masing subset ditampilkan dalam bentuk gambar yaitu pada Gambar 4.1 dan Gambar 4.2 berikut.

Distribusi Dataset:

	Train	Validation	Test
Kelas			
acne	349	99	49
dry	347	103	47
normal	352	101	49
oily	353	100	51
Total	1401	403	196

<Figure size 1200x500 with 0 Axes>

Gambar 4. 1. Tabel Distribusi Dataset Tabel Distribusi Dataset Sumber: Hasil eksekusi kode pada Kaggle Notebook.



Gambar 4. 2. Diagram Batang Distribusi Jumlah Gambar per Kelas pada Set Train, Validation, dan Test Diagram Batang Distribusi.

Berdasarkan Gambar 4.1 dan Gambar 4.2, jumlah citra pada masing-masing subset adalah sebagai berikut:

- Set Pelatihan (*Train*) : 1.401 citra
- Set Validasi (*Validation*): 403 citra
- Set Pengujian (*Test*) : 196 citra
- Total : 2.000 citra

4.1.3 Analisis Distribusi Data

Dari Gambar 4.2 terlihat bahwa distribusi kelas pada ketiga subset relatif seimbang dan mengikuti pola yang konsisten. Tabel Rincian per kelas adalah sebagai berikut:

Tabel 4. 1 Tabel Rincian per kelas

Kelas	Train	Validation	Test	Total per Kelas
acne	349	99	49	497
dry	347	103	47	497
normal	352	101	49	502
oily	353	100	51	504
Total	1.401	403	196	2.000


Persentase pembagian data secara keseluruhan mendekati rasio 70% (*train*) 20% (*validation*) 10% (*test*), yaitu sekitar 70,05% – 20,15% – 9,80%. Ketidakseimbangan yang sangat kecil antar kelas (maksimal 7 citra per kelas) masih berada dalam batas yang dapat ditoleransi dan tidak memerlukan teknik oversampling atau undersampling tambahan pada tahap awal. Distribusi yang cukup merata ini memberikan jaminan bahwa model akan menerima representasi yang proporsional dari setiap jenis kulit selama proses pelatihan, validasi, dan pengujian akhir.

Keberadaan subset validasi yang terpisah juga memungkinkan penerapan *early stopping* dan pemantauan *overfitting* secara objektif, sementara subset pengujian yang benar-benar “*unseen*” akan digunakan sebagai penilaian performa akhir model hybrid MobileNetV2 dengan RBF-SVM yang dikembangkan pada tahapan berikutnya.

4.2 Pra-Pemrosesan dan Augmentasi Data

4.2.1 Visualisasi Sampel Data Asli

Sebelum dilakukan pra-pemrosesan, dilakukan visualisasi terhadap sampel citra asli untuk memahami karakteristik visual masing-masing kelas. Sebanyak dua citra representatif dari setiap kelas pada direktori pelatihan (*train*) ditampilkan pada Gambar 4.3.



Gambar 4. 3. Gambar Asli per Kelas

Dari Gambar 4.3 dapat diamati bahwa:

- Kelas *acne* ditandai dengan adanya *lesi inflamasi*, *papula*, *pustula*, serta kemerahan yang jelas.
- Kelas *dry* menunjukkan tekstur kulit kasar, pengelupasan ringan (*flaking*),

dan warna kemerahan difus terutama pada area pipi serta sekitar hidung.

- c. Kelas normal memiliki permukaan kulit yang rata, pori-pori kecil, serta tidak terdapat lesi atau kemerahan yang signifikan.
- d. Kelas *oily* memperlihatkan kilau berlebih, pori-pori yang tampak membesar, serta tekstur berminyak yang dominan pada zona T (dahi, hidung, dagu).

4.2.2 Teknik Normalisasi Pixel menggunakan MobileNetV2 Preprocessing

Semua citra, baik pada set pelatihan, validasi, maupun pengujian, dinormalisasi menggunakan fungsi `tf.keras.applications.mobilenet_v2.preprocess_input`. Fungsi ini melakukan dua langkah penting:

- a. Mengubah rentang nilai piksel dari [0, 255] menjadi [0, 1].
- b. Melakukan penskalaan *channel-wise* dengan mengurangi nilai *mean ImageNet* ([103.939, 116.779, 123.68] untuk kanal B, G, R) dan membagi dengan standar deviasi yang sesuai, sehingga nilai akhir berada pada rentang [-1, 1].

Normalisasi ini wajib diterapkan agar distribusi input sesuai dengan yang digunakan saat MobileNetV2 dilatih pada dataset *ImageNet*, sehingga ekstraksi fitur dapat berjalan optimal.

4.2.3 Parameter Augmentasi Data yang Diterapkan

Untuk meningkatkan *variabilitas* data pelatihan dan mencegah *overfitting*, diterapkan teknik augmentasi data secara real-time menggunakan *ImageDataGenerator* dengan parameter sebagai berikut:

Tabel 4. 2 Parameter Augmentasi


Parameter	Nilai	Kegunaan
rotation_range	30	Rotasi acak $\pm 30^\circ$
width_shift_range	0.25	Pergeseran horizontal hingga 25% lebar gambar
height_shift_range	0.25	Pergeseran vertikal hingga 25% tinggi gambar

Tabel 4. 2 Lanjutan

Parameter	Nilai	Kegunaan
shear_range	0.2	Transformasi shear hingga 20%
zoom_range	0.3	Zoom in/out acak hingga 30%
horizontal_flip	True	Pembalikan horizontal (realistis untuk wajah manusia)
brightness_range	[0.7, 1.3]	Variasi pencahayaan 70%–130% dari kecerahan asli
channel_shift_range	25.0	Perubahan intensitas acak pada setiap kanal warna
fill_mode	'reflect'	Pengisian piksel baru dengan refleksi (mengurangi artefak)
preprocessing_function	MobileNetV2 preprocess_input	Normalisasi piksel seperti pada subbab 4.2.2

4.2.4 Visualisasi Hasil Augmentasi (8 gambar hasil transformasi)

Hasil augmentasi divisualisasikan dengan mengambil satu batch dari generator pelatihan dan melakukan denormalisasi sementara agar citra dapat ditampilkan dengan benar. Delapan contoh hasil augmentasi ditunjukkan pada Gambar 4.4.



Gambar 4. 4. Hasil Augmentasi Data.

Dari Gambar 4.4 terlihat bahwa augmentasi berhasil menghasilkan variasi yang signifikan, meliputi perubahan sudut pandang, pencahayaan, skala, serta distorsi ringan, namun tetap mempertahankan karakteristik utama masing-masing kelas. Variasi ini sangat penting untuk meningkatkan kemampuan generalisasi model terhadap kondisi pengambilan foto di dunia nyata yang tidak terkendali.

4.3 Pembuatan dan Pelatihan Model Klasifikasi

4.3.1 Arsitektur Model Hybrid MobileNetV2 dengan RBF-SVM

Penelitian ini mengadopsi pendekatan hybrid yang menggabungkan MobileNetV2 sebagai ekstraktor fitur (*feature extractor*) dan Support Vector Machine dengan kernel RBF sebagai klasifikator akhir. Arsitektur ini dipilih karena kemampuan MobileNetV2 dalam menghasilkan representasi fitur yang sangat kaya dan ringkas sekaligus tetap ringan, serta keunggulan SVM-RBF dalam menangani data berdimensi tinggi dengan batas keputusan non-linear yang kompleks.

Pada tahap awal, MobileNetV2 (*pre-trained* pada ImageNet) digunakan dengan *top layer* dihilangkan. Output dari *backbone* ini kemudian diolah melalui:

- a. GlobalAveragePooling2D yang mereduksi dimensi spasial menjadi vektor fitur berdimensi 1280.
- b. Dropout sebesar 0.6 sebagai teknik regularisasi untuk mengurangi overfitting.
- c. Dense dengan 256 neuron menggunakan aktivasi ReLU, dilanjutkan dengan BatchNormalization sebagai lapisan fully-connected tambahan.
- d. Dropout sebesar 0.6 lagi sebagai regularisasi lanjutan.
- e. Dense dengan 4 neuron dan aktivasi softmax sebagai kepala klasifikasi sementara, yang akan diganti dengan SVM pada tahap berikutnya.

4.3.2 Implementasi Transfer Learning dan Fine-Tuning (unfreeze 80 layer terakhir)

Strategi transfer learning yang diterapkan adalah sebagai berikut:

- a. Tahap awal: Seluruh layer pada *backbone* MobileNetV2 dibekukan (*trainable = False*).

- b. Tahap fine-tuning: Setelah model dasar dilatih, dilakukan *unfreezing* sebanyak 80 layer terakhir dari total 155 layer *backbone* MobileNetV2, sehingga hanya lapisan konvolusi tingkat tinggi yang disesuaikan dengan domain citra kulit wajah.

Hasil konfigurasi setelah fine-tuning:

- 1) Total layer keseluruhan model: 160 layer
- 2) Layer yang dapat dilatih (*trainable*): 86 layer
- 3) Layer yang dibekukan (*non-trainable*): 74 layer
- 4) Total parameter: 2.587.972 parameter
- 5) Parameter *trainable*: 2.397.188 (92,6%)
- 6) Parameter *non-trainable*: 190.784 (7,4%)

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 224, 224, 3)	0	-
Conv1 (Conv2D)	(None, 112, 112, 32)	864	input_layer[0][0]
bn_Conv1 (BatchNormalizatio..)	(None, 112, 112, 32)	128	Conv1[0][0]
Conv1_relu (ReLU)	(None, 112, 112, 32)	0	bn_Conv1[0][0]
expanded_conv_dept.. (DepthwiseConv2D)	(None, 112, 112, 32)	288	Conv1_relu[0][0]
expanded_conv_dept.. (BatchNormalizatio..)	(None, 112, 112, 32)	128	expanded_conv_de..
expanded_conv_dept.. (ReLU)	(None, 112, 112, 32)	0	expanded_conv_de..
expanded_conv_proj.. (Conv2D)	(None, 112, 112, 16)	512	expanded_conv_de..
expanded_conv_proj.. (BatchNormalizatio..)	(None, 112, 112, 16)	64	expanded_conv_pr..
block_1_expand (Conv2D)	(None, 112, 112, 96)	1,536	expanded_conv_pr..
block_1_expand_BN (BatchNormalizatio..)	(None, 112, 112, 96)	384	block_1_expand[0..
block_1_expand_relu (ReLU)	(None, 112, 112, 96)	0	block_1_expand_B..
block_1_pad (ZeroPadding2D)	(None, 113, 113, 96)	0	block_1_expand_r..

Gambar 4. 5. Ringkasan Arsitektur Model Hybrid MobileNetV2 setelah fine-tuning

Penggunaan fine-tuning pada 80 layer terakhir memungkinkan model menyesuaikan fitur tingkat tinggi seperti tekstur jerawat, kilau minyak, atau kekasaran kulit kering, tanpa mengganggu fitur *low-level* seperti tepi dan sudut

yang telah dipelajari dengan baik pada ImageNet.

Dengan Intisari Kode Implementasi:

```
base = MobileNetV2(weights='imagenet', include_top=False,
input_shape=(224,224,3))
base.trainable = True
for layer in base.layers[:-80]:      # Bekukan semua kecuali 80 layer terakhir
    layer.trainable = False
x = base.output
x = GlobalAveragePooling2D()(x)
x = Dropout(0.6)(x)
x = Dense(256, activation='relu')(x)
x = BatchNormalization()(x)
x = Dropout(0.6)(x)
predictions = Dense(4, activation='softmax')(x)
model = Model(inputs=base.input, outputs=predictions)

model.compile(optimizer=Adam(3e-4),
              loss='categorical_crossentropy',
              metrics=['accuracy'])
```

4.3.3 Proses Pelatihan Model CNN dengan Callbacks

Proses pelatihan model MobileNetV2 yang telah *define-tune* dilakukan menggunakan 100 epoch maksimum dengan tiga mekanisme *callback* untuk mencegah *overfitting*, mempercepat *konvergensi*, dan menyimpan model terbaik:

- a. **ModelCheckpoint** Menyimpan model hanya ketika terjadi peningkatan `val_accuracy` (`save_best_only=True`). File disimpan dengan nama `best_cnn.keras`.
- b. **EarlyStopping** Memantau `val_accuracy` dengan `patience = 15` epoch. Jika tidak ada perbaikan selama 15 epoch berturut-turut, pelatihan dihentikan secara otomatis dan bobot model dikembalikan ke kondisi terbaik (`restore_best_weights=True`).
- c. **ReduceLROnPlateau** Mengurangi learning rate sebesar faktor 0.4 (dari 3×10^{-4}) jika `val_accuracy` tidak membaik selama 6 epoch berturut-turut, dengan batas bawah `min_lr = 1 \times 10^{-7}`.

Pelatihan dilakukan dengan *optimizer* Adam ($lr = 3 \times 10^{-4}$), fungsi loss *categorical crossentropy*, dan metrik utama *accuracy*. Data pelatihan dialirkan melalui *train_gen* dengan augmentasi real-time, sedangkan data validasi melalui *valid_gen* tanpa augmentasi.

Pelatihan berlangsung selama 83 epoch sebelum dihentikan oleh EarlyStopping. Model terbaik tercatat pada epoch ke-68 dengan validation accuracy tertinggi sebesar 85,36% dan validation loss 0,6544. Setelah epoch tersebut, meskipun akurasi pelatihan terus meningkat hingga mendekati 97%, performa validasi cenderung stagnan atau menurun, mengindikasikan awal terjadinya overfitting.

Peningkatan signifikan terjadi pada 20 epoch pertama, di mana validation accuracy melonjak dari 49,88% menjadi lebih besar dari 70%. Setelah learning rate diturunkan bertahap, model masih mampu meningkatkan validation accuracy secara perlahan hingga mencapai puncaknya di epoch 68.

Tabel 4. 3. Ringkasan Performa pada Beberapa Epoch Penting

Epoch	Train Accuracy	Train Loss	Val Accuracy	Val Loss	Catatan
1	34.07%	2.2275	49.88%	1.6468	Awal pelatihan
16	84.26%	0.3970	79.65%	0.6559	Lonjakan signifikan
22	91.12%	0.2455	78.16%	0.8364	Learning rate turun 1.2×10^{-4}
26	94.65%	0.1610	80.15%	0.7841	Masuk fase stabil
38	95.73%	0.1315	82.88%	0.7075	Learning rate turun 4.8×10^{-5}
40	95.36%	0.1527	83.13%	0.6573	Mendekati puncak
68	90.50%	0.0721	85.36%	0.6544	Model terbaik (disimpan)
83	96.26%	0.1011	84.86%	0.6559	Early stopping aktif

Intisari Kode Pelatihan dengan Callbacks:

```
callbacks = [
    ModelCheckpoint('best_cnn.keras', monitor='val_accuracy',
                    save_best_only=True, verbose=1),
    EarlyStopping(monitor='val_accuracy', patience=15,
                  restore_best_weights=True, verbose=1),
    ReduceLROnPlateau(monitor='val_accuracy', factor=0.4,
                      patience=6, min_lr=1e-7, verbose=1)
]


history = model.fit(
    train_gen,
    epochs=100,
    validation_data=valid_gen,
    callbacks=callbacks,
    verbose=1
)

# Memuat kembali model terbaik
model = tf.keras.models.load_model('best_cnn.keras')
```


Model terbaik dari epoch 68 dengan validation accuracy 85,36% selanjutnya digunakan sebagai feature extractor untuk tahap ekstraksi fitur dan pelatihan classifier RBF-SVM pada subbab berikutnya.

4.3.4 Analisis Kurva Akurasi dan Loss (Training vs Validation)

Untuk mengevaluasi proses pembelajaran dan mendeteksi potensi *overfitting/underfitting*, dilakukan visualisasi kurva akurasi dan *loss* pada set pelatihan dan validasi selama 83 epoch pelatihan. Hasilnya ditampilkan pada Gambar 4.6 dan Gambar 4.7.



Gambar 4. 6. Kurva Akurasi Model Selama Pelatihan.



Gambar 4. 7. Kurva Loss Model Selama Pelatihan

Interpretasi dan Analisis:

Fase Awal (Epoch 1–20)

- Akurasi pelatihan meningkat sangat cepat dari 34,28% ke 90%, sementara akurasi validasi naik dari 49,88% ke 78%.
- Loss pelatihan turun drastis dari 2.2275 ke 0.4, sedangkan *loss* validasi turun dari 1,6468 menunjukkan *fluktuasi* yang cukup besar.
- Hal ini menunjukkan model sedang belajar fitur-fitur dasar kulit wajah dengan sangat efektif berkat transfer learning dari MobileNetV2.

Fase Stabilisasi dan Fine-Tuning (Epoch 21–55)

- Akurasi pelatihan terus meningkat secara konsisten menuju 97%, sedangkan akurasi validasi menunjukkan tren naik yang lebih lambat namun stabil, mencapai 85,11%.
- Loss validasi mengalami penurunan bertahap dengan beberapa *osilasi*, namun secara umum menurun dari 0.9 ke 0.63 sampai 0.67.
- Terlihat adanya gap yang semakin lebar antara *train* dan validation accuracy dari 10% menjadi 15%, mengindikasikan awal terjadinya overfitting ringan, tetapi masih terkendali berkat augmentasi data dan callbacks.

Fase Akhir dan Efek Callbacks (Epoch 41–69)

- Setelah *learning rate* diturunkan secara bertahap, kurva validasi menjadi

lebih halus dan akurasi validasi berhasil mencapai puncaknya sebesar 85,36% pada epoch ke-68.

- b. Setelah epoch 68, *val_accuracy* hanya *berfluktuasi* sangat kecil tanpa perbaikan signifikan selama 15 epoch berikutnya sehingga *EarlyStopping* aktif pada epoch 83 dan secara otomatis mengembalikan bobot ke epoch 68.
- c. Train accuracy terus meningkat hingga lebih dari 97%, sedangkan validation accuracy *stagnan* mengkonfirmasi adanya *overfitting moderat* di akhir pelatihan.

Dengan begitu kesimpulan yang di dapat dari kurva pembelajaran ialah seperti ini:

- a. Model berhasil mencapai *konvergensi* yang sangat baik dengan validation accuracy tertinggi 85,36% pada epoch 68.
- b. Terdapat *overfitting moderat gap* akurasi 12–14% di akhir training, namun masih wajar untuk dataset medis berukuran kecil yaitu 1.401 citra latih.
- c. Kombinasi augmentasi agresif, Dropout sebesar 0.6, BatchNormalization, ReduceLROnPlateau, dan EarlyStopping terbukti sangat efektif mencegah overfitting yang lebih parah serta memastikan pemilihan bobot terbaik secara otomatis.
- d. Performa CNN dengan softmax pada tahap ini sudah sangat baik (85,36%), namun masih terdapat ruang perbaikan yang akan diatasi pada tahap *hybrid* dengan mengganti klasifikator menjadi RBF-SVM

Hasil analisis kurva ini menjadi dasar pemilihan model terbaik pada epoch 68 validation accuracy 85,36% yang akan digunakan sebagai *feature extractor* untuk tahap ekstraksi fitur dan pelatihan klasifikator hybrid MobileNetV2 dengan RBF-SVM pada subbab berikutnya.

4.3.5 Ekstraksi Fitur menggunakan Model Terbaik dan Persiapan Pelatihan RBF-SVM

Setelah diperoleh model CNN terbaik epoch ke-68, validation accuracy 85,36%, lapisan klasifikasi akhir dense dan softmax dihilangkan dan model hanya digunakan sebagai ekstraktor fitur yang tetap. Output yang diambil adalah vektor

fitur berdimensi 1280 dari lapisan GlobalAveragePooling2D diberi nama 'gap', yang merupakan representasi tingkat tinggi dan sangat informatif dari citra input.

Prosedur Ekstraksi Fitur

- Model ekstraktor fitur dibuat dengan mengambil *output* dari lapisan 'gap':

```
feat_extractor = Model(inputs=model.input,
                      outputs=model.get_layer('gap').output)
```

- Fitur diekstrak secara batch dari *train_gen* dan *test_gen* tanpa augmentasi, hanya normalisasi MobileNetV2.
- Setiap citra menghasilkan vektor fitur sepanjang 1280 dimensi.

Ringkasan hasil ekstraksi fitur dari dataset pelatihan dan pengujian dirangkum pada Tabel 4.4 berikut, yang mencakup jumlah sampel, dimensi fitur, serta ukuran matriks akhir.

Tabel 4. 4. Hasil ekstraksi fitur

Dataset	Jumlah Sampel	Dimensi Fitur	Ukuran Matriks Fitur
Pelatihan	1.401	1280	(1401, 1280)
Pengujian	196	1280	(196, 1280)

Selain itu, Tabel 4.5 memberikan ringkasan komprehensif mengenai komponen kunci proses ekstraksi, termasuk model yang digunakan dan bentuk akhir data.

Tabel 4. 5. Ringkasan Hasil Ekstraksi Fitur

Komponen	Nilai/Keterangan
Model terbaik yang digunakan	Epoch ke-68 dengan validation accuracy sebesar 85,36%
Lapisan output fitur	GlobalAveragePooling2D (gap)
Dimensi fitur per citra	1280 dimensi
Total fitur pelatihan	1401 citra menghasilkan 1401 vektor fitur
Total fitur pengujian	196 citra menghasilkan 196 vektor fitur
Bentuk akhir matriks	X_train: (1401, 1280), X_test: (196, 1280)

Keunggulan representasi ini adalah:

- Telah melalui proses fine-tuning khusus pada domain citra kondisi kulit wajah.
- Sangat kompak, dibandingkan citra mentah $224 \times 224 \times 3 = 150.528$ dimensi.
- Mengandung informasi hierarkis tinggi yang sangat relevan untuk membedakan kelas *acne*, *dry*, *normal*, dan *oily*.

Intisari Kode Ekstraksi Fitur:

```
# Membuat feature extractor (output dari GAP)
feat_extractor = Model(inputs=model.input,
                       outputs=model.get_layer('gap').output)

# Fungsi ekstraksi fitur dari generator
def extract_features(gen, n_samples):
    gen.reset()
    feats, labels = [], []
    for i in range(n_samples):
        img, label = next(gen)
        f = feat_extractor.predict(img, verbose=0)
        feats.append(f[0])
        labels.append(np.argmax(label[0]))
    return np.array(feats), np.array(labels)

# Ekstraksi fitur train dan test
X_train, y_train = extract_features(train_gen, len(train_gen_filenames))
X_test, y_test = extract_features(test_gen, len(test_gen_filenames))

print(f"Fitur train: {X_train.shape}, Fitur test: {X_test.shape}")
```

Vektor fitur X_{train} (1401×1280) dan X_{test} (196×1280) yang telah diekstrak ini selanjutnya digunakan sebagai input untuk tahap optimasi hyperparameter dan pelatihan klasifikator Support Vector Machine dengan kernel Radial Basis Function (RBF-SVM) pada subbab berikutnya. Pendekatan hybrid MobileNetV2 dengan RBF-SVM ini diharapkan dapat mengatasi keterbatasan kepala klasifikasi softmax serta meningkatkan akurasi klasifikasi secara signifikan.

4.3.6 Normalisasi Fitur dan Pelatihan Classifier RBF-SVM

Sebelum melatih Support Vector Machine dengan kernel Radial Basis Function (RBF-SVM), seluruh vektor fitur yang telah diekstrak dari lapisan GlobalAveragePooling2D (dimensi 1280) harus dinormalisasi agar setiap fitur

memiliki $mean = 0$ dan standar $deviasi = 1$. Normalisasi ini sangat krusial pada SVM berbasis kernel RBF karena jarak garis lurus (*Euclidean*) dalam ruang fitur sangat sensitif terhadap skala fitur.

Prosedur Normalisasi

- Digunakan `StandardScaler` dari `scikit-learn`.
- Parameter skala $mean$ dan standar dihitung hanya dari data pelatihan.
- Data pengujian hanya ditransformasi menggunakan parameter yang sama transform untuk mencegah data *leakage*.

Setelah normalisasi:

- $X_{train_s} : (1401 \times 1280)$ terdistribusi standar
- $X_{test_s} : (196 \times 1280)$ terdistribusi standar dengan parameter dari data latih

4.3.7 Hasil GridSearchCV dan Parameter Optimal SVM

Optimasi hyperparameter dilakukan menggunakan `GridSearchCV` dengan 5-fold stratified cross-validation pada data pelatihan. Ruang pencarian hyperparameter yang dieksplorasi dirangkum pada tabel 4.6 berikut.

Tabel 4. 6. Ruang Pencarian Hyperparameter RBF-SVM

Hyperparameter	Nilai yang Diuji
C	[30, 50, 80, 100, 150, 200]
gamma	[0.0005, 0.001, 0.0015, 0.002, 'scale']
kernel	['rbf'] (tetap)

Total kombinasi ada 6×5 jadi ada 30 kandidat, sehingga ada 150 fitting

Hasil `GridSearchCV`

Best parameters: {'C': 30, 'gamma': 0.001, 'kernel': 'rbf'}

Hasil `GridSearchCV` menunjukkan parameter terbaik sebagai berikut, yang diringkas pada Tabel 4.7.

Tabel 4. 7. Parameter RBF-SVM Terbaik

Parameter	Nilai Optimal	Keterangan
C	30	Regularisasi sedang, mengutamakan generalisasi
gamma	0.001	Kernel RBF dengan pengaruh luas (smooth boundary)
kernel	rbf	Kernel non-linear terbaik untuk data berdimensi tinggi

Interpretasi parameter optimal:

- C = 30: Regularisasi sedang hingga kuat, menyeimbangkan kompleksitas model dan toleransi terhadap *misclassification* demi generalisasi terbaik.
- gamma = 0.001: Nilai gamma kecil menghasilkan *decision boundary* yang relatif halus dan luas, sangat cocok untuk fitur berdimensi tinggi (1280) yang sudah sangat informatif dari MobileNetV2 fine-tuned.

Intisari Kode Normalisasi dan GridSearchCV:

```
# Normalisasi fitur
scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
X_test_s = scaler.transform(X_test)

# GridSearch untuk RBF-SVM
param_grid = {
    'C': [30, 50, 80, 100, 150, 200],
    'gamma': [0.0005, 0.001, 0.0015, 0.002, 'scale'],
    'kernel': ['rbf']
}
svm_grid = GridSearchCV(SVC(random_state=42), param_grid,
                        cv=5, n_jobs=-1, verbose=1)
svm_grid.fit(X_train_s, y_train)

print("Best parameters:", svm_grid.best_params_)
# Output: {'C': 30, 'gamma': 0.001, 'kernel': 'rbf'}
```

Dengan kombinasi parameter terbaik ini, model hybrid MobileNetV2 *feature extractor* dengan RBF-SVM classifier siap dievaluasi pada data pengujian independen untuk mendapatkan performa akhir yang objektif.


4.3.8 Evaluasi Performa Model Hybrid Akhir pada Data Pengujian Independen

Model *hybrid* akhir MobileNetV2 (fine-tuned) dengan RBF-SVM

dievaluasi pada data pengujian independen yang tidak pernah dilihat selama pelatihan maupun validasi. Evaluasi dilakukan menggunakan metrik standar klasifikasi *multilabel*. Hasil Utama Akurasi Keseluruhan sebesar 90,31%. Hasil evaluasi lengkap model hybrid akhir pada data pengujian independen (196 citra) disajikan dalam Classification Report pada Tabel 4.8 berikut, yang mencakup precision, recall, F1-score per kelas, serta metrik rata-rata.

Tabel 4. 8. Classification Report Model Hybrid Akhir

Kelas	Precision	Recall	F1-Score	Support
Acne	0.96	0.94	0.95	49
Dry	0.75	0.94	0.83	47
Normal	0.95	0.71	0.81	49
Oily	0.87	0.88	0.87	51
Accuracy			0.87	196
Macro Average	0.88	0.87	0.87	196
Weighted Average	0.88	0.87	0.87	196



Gambar 4. 8. Confusion Matrix Model Hybrid. (MobileNetV2 dengan RBF-SVM)

Analisis Mendalam hasil Confusion Matrix:

Temuan Utama dan Interpretasi Akademik

- a. *Acne*: Performa hampir sempurna dengan F1-score 0.9 karena tekstur jerawat sangat khas dan mudah dibedakan.
- b. *Dry*: Recall tinggi 94%, tetapi precision terendah 80% karena beberapa citra normal atau *oily* terdeteksi sebagai *dry*. Tekstur kasar kulit kering kadang tumpang tindih dengan kulit normal yang kurang hidrasi.
- c. Normal: Kelas paling sulit recall 82% karena sebagian citra normal salah diklasifikasikan sebagai *dry* atau *oily*, wajar karena kelas normal berada di tengah spektrum.
- d. *Oily*: Seimbang dan sangat baik F1-score 0.91.

Dibandingkan dengan model CNN murni (kepala softmax) yang hanya mencapai 85,36%, model hybrid MobileNetV2 dengan RBF-SVM berhasil mencapai 90,31% dengan peningkatan sebesar 4,95% pada data test independen, yang di mana RBF-SVM berhasil mengatasi keterbatasan kepala softmax dan meningkatkan generalisasi secara signifikan.

Intisari Kode Evaluasi Akhir:

```
y_pred = best_svm.predict(X_test_s)
acc = accuracy_score(y_test, y_pred)

print("="*65)
print(f"FINAL TEST ACCURACY HYBRID MODEL: {acc*100:.2f}%")
print("="*65)
print(classification_report(y_test, y_pred,
target_names=['acne','dry','normal','oily']))

# Confusion matrix
cm = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(8,6))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
            xticklabels=['acne','dry','normal','oily'],
            yticklabels=['acne','dry','normal','oily'])
plt.title(f'Confusion Matrix Hybrid Model\nAccuracy: {acc*100:.2f}%')
plt.xlabel('Predicted')
plt.ylabel('True')
plt.show()
```

Model hybrid MobileNetV2 RBF-SVM dengan akurasi 90,31% pada data pengujian independen telah terbukti superior dibandingkan CNN murni, memiliki

generalisasi yang sangat baik, serta siap diimplementasikan pada aplikasi mobile untuk deteksi jenis dan kondisi kulit wajah berbasis selfie.

4.3.9 Perbandingan Performa Model

Untuk membuktikan kontribusi masing-masing komponen metodologi yang diusulkan, dilakukan perbandingan performa secara ablatasi terhadap tiga varian model pada data pengujian independen yang sama 196 citra.

Tabel 4. 9. Perbandingan Performa Model pada Data Pengujian

No	Model	Strategi Pelatihan	Akurasi Test	Peningkatan vs Baseline
1	Baseline MobileNetV2 (tanpa fine-tuning)	Semua layer backbone dibekukan, hanya latih kepala klasifikasi	75,00%	—
2	MobileNetV2 + Fine-tuning (kepala softmax)	Unfreeze 80 layer terakhir + pelatihan end-to-end	85,36%	+10–11%
3	Model Hybrid (MobileNetV2 fine-tuned + RBF-SVM)	Fine-tuning + ekstraksi fitur + RBF-SVM optimal	90,31%	+15,31%

a. Baseline MobileNetV2 (*frozen backbone*)

- 1) Semua layer *backbone* MobileNetV2 dibekukan.
- 2) Hanya kepala klasifikasi yang dilatih.
- 3) Akurasi test: 75.00%

Fitur generik ImageNet masih cukup baik, tetapi belum optimal untuk domain kulit wajah.

b. MobileNetV2 dengan *Fine-tuning* (kepala softmax)

- 1) *Fine-tuning* mendalam.
- 2) Validation accuracy terbaik: 85.36%
- 3) Estimasi akurasi pada data test berada di kisaran 85 sampai 86%.

Fine-tuning berhasil menyesuaikan fitur tingkat tinggi dengan peningkatan sebesar 10 sampai 11 poin dibandingkan baseline.

c. Model Hybrid (MobileNetV2 fine-tuned dengan RBF-SVM)

- 1) Menggunakan fitur 1280-dimensi dari model *fine-tuned* terbaik.
- 2) Klasifikasi oleh RBF-SVM dengan hyperparameter optimal.
- 3) Akurasi test: 90.31%
- 4) Peningkatan absolut 15.31 poin persentase dibandingkan baseline.

Peningkatan 4 sampai 5 poin dibandingkan CNN murni dengan softmax membuktikan bahwa RBF-SVM jauh lebih unggul daripada lapisan softmax dalam memanfaatkan representasi fitur berdimensi tinggi pada dataset kecil-sedang.

Kesimpulan Perbandingan Kombinasi *fine-tuning* mendalam pada MobileNetV2 dan penggantian kepala klasifikasi dengan RBF-SVM yang dioptimasi menggunakan GridSearchCV memberikan peningkatan performa yang sangat signifikan dan konsisten. Model *hybrid* akhir berhasil mengatasi keterbatasan kepala *softmax* khususnya pada kelas normal dan *dry* yang sering tumpang tindih, serta memaksimalkan kemampuan generalisasi pada data baru.

Intisari Kode Perbandingan dengan Baseline:

```
# Baseline: MobileNetV2 tanpa fine-tuning
base_frozen = MobileNetV2(weights='imagenet', include_top=False,
input_shape=(224,224,3))
base_frozen.trainable = False # Bekukan semua layer
# ... (sama kepala klasifikasi seperti sebelumnya)
model_frozen.compile(optimizer=Adam(3e-4), loss='categorical_crossentropy',
metrics=['accuracy'])
model_frozen.fit(train_gen, epochs=30, validation_data=valid_gen, verbose=0)

baseline_acc = model_frozen.evaluate(test_gen, verbose=0)[1]
hybrid_acc = acc # 0.8673 dari SVM


print(f"Baseline (frozen): {baseline_acc*100:.2f}%")
print(f"Dengan Fine-tuning + Hybrid SVM: {hybrid_acc*100:.2f}%")
print(f"Peningkatan: {hybrid_acc*100 - baseline_acc*100:.2f}%")
```

Hasil ini menjadi bukti *empiris* kuat bahwa metodologi *hybrid* yang diusulkan dalam penelitian ini merupakan pendekatan terbaik dan paling optimal

untuk tugas klasifikasi jenis dan kondisi kulit wajah berbasis citra *selfie*, dengan akurasi tertinggi 90.31% pada data pengujian independen.

4.3.10 Analisis Kesalahan Klasifikasi (Error Analysis)

Meskipun model *hybrid* akhir berhasil mencapai akurasi 90,31% pada data pengujian independen, terdapat 19 citra dari 196 sebesar 9,69% yang masih salah diklasifikasikan. Untuk memahami keterbatasan model dan memberikan arah perbaikan di masa depan, dilakukan analisis mendalam terhadap contoh-contoh kesalahan klasifikasi representatif yang ditampilkan pada Gambar 4.9.



Gambar 4. 9. Dua Belas Contoh Kesalahan Klasifikasi Model Hybrid

Berdasarkan observasi visual dan kategorisasi manual terhadap 26 citra salah, teridentifikasi pola-pola kesalahan dominan:

a. Normal menjadi *Dry*

Penyebab utama:

- 1) Pencahayaan buruk, bayangan, atau foto di dalam ruangan membuat kulit normal tampak kusam dan kasar mirip kulit kering.

2) Penggunaan filter matte atau makeup yang menghilangkan kilau alami.

3) Kulit normal yang sedikit dehidrasi pada area seperti pipi (T-zone).

b. Normal menjadi *Oily* atau *Dry* menjadi *Oily*

Penyebab utama:

1) Penggunaan skincare berbasis *oil* yang memberikan efek glow tinggi.

2) *Flash* langsung atau pencahayaan lampu yang menciptakan refleksi kuat di dahi dan pipi.

3) Kulit kering yang baru diaplikasi pelembap sehingga muncul kilau buatan.

c. *Acne* menjadi *Dry* atau *Dry* menjadi Normal

Penyebab utama:

1) Jerawat dalam fase penyembuhan.

2) Resolusi rendah atau jarak foto jauh sehingga detail jerawat tidak terlihat.

Kesimpulan dari Error Analysis:

a. Kelas Normal tetap menjadi kelas paling rentan salah klasifikasi karena tidak memiliki fitur ekstrem dan berada di tengah-tengah spektrum kulit.

b. Faktor eksternal seperti pencahayaan, filter, makeup, skincare, flash masih menjadi penyebab utama kesalahan, ini adalah tantangan *inheren* dalam klasifikasi kulit dari *selfie* tanpa kontrol lingkungan.

c. Model sudah sangat baik dalam menangkap fitur ekstrem *acne* dan *oily* yang sangat berminyak, terbukti dari precision dan recall tinggi pada kedua kelas tersebut.

d. Dengan hanya 9,69% *error rate*, model *hybrid* ini sudah berada pada tingkat performa yang sangat baik dan realistis untuk aplikasi dunia nyata.


4.3.11 Pengujian Efisiensi Komputasi Model

Meskipun model hybrid MobileNetV2 RBF-SVM telah menunjukkan performa klasifikasi yang superior dengan akurasi 90,31% dan error rate hanya 9,69%, keberhasilan sebuah model tidak hanya ditentukan oleh akurasi semata, melainkan juga oleh efisiensi komputasinya untuk mendukung implementasi praktis pada perangkat berdaya rendah dan aplikasi real-time. Oleh karena itu, dilakukan pengujian efisiensi untuk menjawab pertanyaan penelitian mengenai seberapa cepat, ringan, dan hemat sumber daya model hybrid dalam mengklasifikasikan citra jenis kulit wajah.

Pengukuran meliputi waktu inferensi rata-rata per citra, ukuran model akhir, estimasi penggunaan memori tambahan, serta utilisasi hardware. Pengujian dilakukan pada satu citra contoh dari set pengujian independen, diulang sebanyak 20 iterasi untuk mendapatkan nilai rata-rata yang stabil. Hasil pengujian efisiensi disajikan pada Tabel 4.10 dan divisualisasikan pada Gambar 4.10 dan Gambar 4.11.


Tabel 4. 10 Hasil pengujian efisiensi

Metrik	Baseline	Fine tuned	Hybrid	Keterangan
Waktu Rata-rata per Citra (detik)	0,273	0,272	0,072	Hybrid lebih cepat
Ukuran Model Akhir (MB)	29	29	43	Tambahan 14 MB dari SVM dan scaler
Penggunaan RAM Tambahan (GB)	0,01	0,01	0,01	Minimal di ketiga varian
Utilisasi GPU/CPU	GPU 0% / CPU ~5%	GPU 0% / CPU ~5%	GPU ~0% / CPU ~5–10%	Sangat ringan, cocok untuk perangkat mobile



Gambar 4. 10. Perbandingan Waktu Inferensi Rata-rata per Citra

Gambar 4.10 menunjukkan bahwa model hybrid memiliki waktu inferensi yang jauh lebih rendah dibandingkan kedua varian model. Dengan waktu rata-rata hanya 72 ms per citra, model hybrid mencapai throughput sekitar 13,9 citra per detik (FPS), yang memenuhi syarat untuk aplikasi real-time berbasis kamera selfie.



Gambar 4. 11. Perbandingan Ukuran Model Akhir

Ukuran model hybrid akhir mencapai sekitar 43 MB, hanya meningkat sekitar 14 MB dibandingkan varian CNN murni. Perbedaan ukuran ini disebabkan oleh perbedaan format penyimpanan model. Komponen CNN pada baseline dan fine-tuned disimpan dalam format *.keras*, yang mengintegrasikan arsitektur, bobot, serta konfigurasi model dalam satu file. Sebaliknya, komponen klasifier SVM dengan kernel RBF disimpan menggunakan format *.pkl* sebagai objek pickled dari scikit-learn yang mencakup parameter kernel, support vectors, serta scaler untuk normalisasi fitur. Ukuran model hybrid ditentukan dengan menambahkan ukuran file *.keras* dari ekstraktor fitur yang telah disempurnakan, ukuran file *.pkl* SVM, dan ukuran scaler yang diperkirakan sekitar 0,5 MB. Oleh karena itu, ukuran totalnya lebih besar. Meskipun ini mewakili peningkatan sekitar 48 persen dibandingkan dengan versi ukuran baseline dan fine-tuned, 43 MB masih sangat layak untuk deployment pada perangkat mobile karena perangkat tersebut umumnya mendukung model hingga ratusan MB tanpa masalah signifikan.

Hasil pengujian efisiensi menunjukkan bahwa model *hybrid* tidak hanya unggul dalam hal akurasi, tetapi juga memiliki karakteristik komputasi yang sangat

efisien. Waktu inferensi 72 ms per citra memungkinkan penerapan model pada aplikasi mobile untuk analisis kulit wajah secara instan tanpa latensi yang mengganggu pengalaman pengguna. Penambahan ukuran model yang relatif kecil sebanding dengan peningkatan akurasi sebesar 15,31 poin persentase dibandingkan baseline frozen, serta 4,95–5 poin dibandingkan CNN murni dengan kepala softmax.

Dengan demikian, model hybrid yang diusulkan dalam penelitian ini tidak hanya superior dalam performa klasifikasi, tetapi juga memenuhi kriteria efisiensi komputasi dan ukuran model yang diperlukan untuk implementasi praktis pada perangkat berdaya rendah, sehingga mendukung tujuan akhir penelitian yaitu pengembangan sistem deteksi jenis kulit wajah berbasis citra selfie yang akurat, cepat, dan dapat diakses secara luas.

Intisari Kode Pengujian Efisiensi:

```
test_gen.reset()
img_batch, _ = next(test_gen)
img_batch = img_batch[:1] # batch size 1
num_iterations = 20
baseline_times = []
finetuned_times = []
hybrid_times = []

for _ in range(num_iterations):
    # Baseline
    start = time.time()
    _ = model_baseline.predict(img_batch, verbose=0)
    baseline_times.append(time.time() - start)

    # Fine-tuned
    start = time.time()
    _ = model.predict(img_batch, verbose=0)
    finetuned_times.append(time.time() - start)

    # Hybrid
    start = time.time()
    feat = feat_extractor.predict(img_batch, verbose=0)
    feat_time = time.time() - start
    start_svm = time.time()
    _ = best_svm.predict(scaler.transform(feat))
    svm_time = time.time() - start_svm
    hybrid_times.append(feat_time + svm_time)

# Rata-rata waktu inferensi
avg_baseline = np.mean(baseline_times)
avg_finetuned = np.mean(finetuned_times)
avg_hybrid = np.mean(hybrid_times)
```

```
# Ukuran model
baseline_size = os.path.getsize('baseline_cnn.keras') / (1024**2)
finetuned_size = os.path.getsize('best_cnn.keras') / (1024**2)
svm_size = os.path.getsize('hybrid_svm_classifier_NEW.pkl') / (1024**2)
hybrid_size = finetuned_size + svm_size + 0.5 # scaler ~0.5 MB
```

Hasil pengujian efisiensi ini menjadi bukti empiris tambahan bahwa metodologi hybrid yang diusulkan tidak hanya meningkatkan akurasi secara signifikan, tetapi juga mempertahankan (bahkan meningkatkan) efisiensi komputasi, menjadikannya solusi yang seimbang dan layak untuk aplikasi praktis di bidang dermatologi berbasis kecerdasan buatan.


4.4 Implementasi Sistem ke Dalam Aplikasi Web

Setelah model *hybrid* MobileNetV2 dengan RBF-SVM mencapai performa optimal, sistem dikemas menjadi aplikasi web bernama *FACEDX* yang dapat diakses secara publik melalui domain <https://facedx.web.id>. Implementasi mengadopsi arsitektur pemisahan frontend dan backend untuk memastikan skalabilitas, keamanan, dan kemudahan pemeliharaan.

4.4.1 Desain Antarmuka Pengguna (UI/UX)


Desain antarmuka dirancang menggunakan Figma dengan pendekatan *clean*, *modern*, dan *user friendly*. Pemilihan elemen visual adalah sebagai berikut:

- a. Warna *primer*: #17D4B3 (hijau telur asin) memberikan kesan segar, alami, dan terkait kesehatan kulit.
- b. Warna *sekunder*: #B1F8EB memberikan kontras lembut dan meningkatkan keterbacaan.
- c. Tipografi: Poppins font sans-serif yang modern, mudah dibaca di semua ukuran layar.
- d. Layout: Responsif dengan Tailwind CSS, mengadopsi pendekatan *mobile-first*, grid 12 kolom, dan spacing konsisten.



Gambar 4. 12. Tampilan Halaman Utama Aplikasi FACEDX

Dari Gambar 4.10 memperlihatkan desain layar beranda aplikasi FACEDX. Tata letaknya menampilkan warna hijau telur yang segar dan dominan (#17D4B3), tombol pemindai wajah yang mudah diakses, dan navigasi sederhana untuk memastikan pengguna merasa nyaman setelah membuka aplikasi.



Gambar 4. 13. Proses Upload Foto dan Hasil Prediksi

Pada Gambar 4.11 menampilkan hasil desain untuk proses upload foto wajah pengguna serta tampilan hasil prediksi aplikasi FACEDX. Pada layar ini, pengguna dapat melihat foto yang telah diupload, diikuti dengan hasil prediksi kondisi kulit yang ditampilkan jelas di bagian bawah foto. Di sebelah kanan,

ditampilkan rekomendasi perawatan yang sesuai, seperti saran produk, tips harian, atau langkah perawatan kulit berdasarkan hasil analisis. Desain tetap mempertahankan warna primer #17D4B3 untuk elemen penting, layout yang bersih, serta fokus pada kemudahan membaca informasi hasil prediksi.

4.4.2 Integrasi Frontend dan Backend

Integrasi antara frontend dan backend dirancang dengan arsitektur modern yang sepenuhnya terpisah agar memudahkan pengembangan, *debugging*, dan *scaling* di masa depan. Frontend dibangun menggunakan stack React.js dengan Vite dan Tailwind CSS, dipilih karena kombinasi ini menawarkan kecepatan *build* yang sangat tinggi, pengelolaan komponen yang rapi, serta sistem styling berbasis *utility-first*, yang memungkinkan pembuatan antarmuka responsif dan konsisten tanpa menulis CSS custom berlebihan. Desain seluruh komponen diimplementasikan sebagai *reusable* component sehingga perubahan tema atau layout dapat dilakukan secara terpusat dalam hitungan menit.

Backend dikembangkan menggunakan Flask sebagai web framework utama dan Gunicorn sebagai production WSGI server. Pemilihan Flask didasarkan pada sifatnya yang ringan, fleksibel, dan sangat cocok untuk melayani model machine learning berukuran besar. Seluruh logika prediksi yaitu penerimaan file, deteksi wajah dengan OpenCV Haar Cascade, cropping wajah, preprocessing identik dengan training, ekstraksi fitur, scaling, hingga inferensi SVM, dikemas dalam satu route utama *predict* dengan metode POST. Respons dikembalikan dalam format JSON yang ringkas namun informatif, berisi jenis kulit, confidence score, dan pesan status.

4.4.3 Pengujian Lokal dan Error Handling


Pengujian end-to-end lokal dilakukan untuk memastikan fungsionalitas keseluruhan aplikasi sebelum Deployment. Pengujian fungsional menunjukkan unggahan foto wajah berhasil diproses dan prediksi yang akurat diberikan untuk semua 50 gambar sampel yang diambil dari data uji. Menurut pengamatan manual, aplikasi berjalan lancar tanpa lag yang terlihat.

Selanjutnya, pengujian responsivitas dilakukan pada berbagai perangkat, termasuk komputer, dan perangkat seluler. Hasilnya menunjukkan bahwa antarmuka pengguna aplikasi beradaptasi dengan baik pada berbagai ukuran.

Mengenai penanganan kesalahan, semua kasus kesalahan yang direncanakan berhasil ditangani dengan pesan kesalahan yang jelas dan informatif. Berikut merangkum implementasi *error handling* yang telah diterapkan pada aplikasi FACEDX, beserta kondisi error, pesan yang ditampilkan kepada pengguna, serta status kode HTTP yang sesuai. Tabel ini mencakup tiga kasus error utama yang paling sering terjadi selama pengujian.

Tabel 4. 11. *Error Handling* yang Diimplementasikan

Kondisi	Pesan Error	Status Kode
Wajah tidak terdeteksi	“Wajah tidak terdeteksi. Pastikan wajah terlihat jelas dan cukup besar.”	400
File bukan gambar	Otomatis ditolak oleh Python Imaging Library (PIL)	400
Ukuran file > 16 MB	Request entity too large	413



Gambar 4. 14. Contoh Error Handling Wajah Tidak Terdeteksi

Gambar 4.12 adalah tampilan contoh pesan error handling pada aplikasi FACEDX ketika wajah tidak terdeteksi dalam foto yang diunggah. Gambar ini menunjukkan antarmuka yang tetap clean dan user-friendly meskipun terjadi

kesalahan: muncul notifikasi berwarna merah dengan pesan jelas “Wajah tidak terdeteksi. Pastikan wajah terlihat jelas dan cukup besar.”


Desain error ini menggunakan warna merah yang lembut untuk background notifikasi agar tidak mengganggu, namun tetap mudah dibaca dan memberikan pengalaman pengguna yang baik bahkan saat terjadi kegagalan proses prediksi.

4.5 Deployment

Aplikasi web *FACEDX* berhasil dideploy ke lingkungan produksi menggunakan platform Railway.app dengan arsitektur dua service terpisah agar memenuhi prinsip *separation of concerns* dan mempermudah scaling di masa depan. Konfigurasi deployment adalah sebagai berikut:

- a. **Frontend Service:** *Static site* hasil build React.js dengan Vite dan Tailwind CSS, di deploy otomatis dari branch main pada repository GitHub.
- b. **Backend Service:** Aplikasi Flask dan Gunicorn yang memuat model TensorFlow, scaler, dan classifier SVM, di deploy dari branch backend. Railway secara otomatis membaca requirements.txt dan Procfile untuk menjalankan server produksi.

Aplikasi produksi dapat diakses secara publik dan gratis oleh siapa saja melalui domain <https://facedx.web.id>



Gambar 4. 15. Aplikasi FACEDX dalam Keadaan Live

Pada gambar 4.13 adalah tampilan aplikasi FACEDX yang telah berhasil di deploy dan berjalan secara live pada domain <https://facedx.web.id>. Gambar ini menunjukkan antarmuka aplikasi dalam mode desktop, dengan layout penuh yang responsif, elemen visual utama seperti halaman utama, dan navigasi yang terlihat jelas serta selaras dengan desain clean dan modern yang telah dirancang sebelumnya.

Tampilan live ini membuktikan bahwa proses deployment frontend dan backend berjalan sukses, sehingga aplikasi siap digunakan oleh pengguna secara publik tanpa kendala teknis yang signifikan.

BAB V PENUTUP

5.1 Kesimpulan

Berdasarkan seluruh proses penelitian yang telah dilakukan, dapat disimpulkan sebagai berikut:

- a. Model klasifikasi jenis kulit wajah telah berhasil dikembangkan menggunakan pendekatan hybrid MobileNetV2 fine-tuned dan RBF-SVM yang terbukti sangat efektif. Pipeline yang diusulkan mencakup fine-tuning mendalam MobileNetV2 pada dataset sebanyak 2.000 citra (1.401 latih, 403 validasi, 196 pengujian), ekstraksi fitur 1280-dimensi dari lapisan GlobalAveragePooling2D, normalisasi fitur dengan StandardScaler, serta pelatihan klasifikator RBF-SVM dengan hyperparameter optimal $C = 30$, $\gamma = 0.001$ yang diperoleh melalui GridSearchCV 5 fold.
- b. Model hybrid akhir mencapai akurasi pengujian tertinggi 90,31% pada data test independen dengan 196 citra, dengan macro-average precision 0,91, recall 0,90, dan F1-score 0,90. Performa ini secara signifikan melampaui:
 - 1) Baseline MobileNetV2 tanpa fine-tuning: 75,00% mengalami peningkatan 15,31 poin.
 - 2) Varian CNN murni softmax terbaik: 85,36% mengalami peningkatan +4,95 poin pada test set.

Kelas acne dan oily menunjukkan performa hampir sempurna, sedangkan kelas normal dan dry tetap menjadi tantangan utama karena overlap tekstur dan pengaruh faktor eksternal seperti pencahayaan, skincare, filter.

- c. Seluruh pipeline telah berhasil diimplementasikan menjadi aplikasi web publik bernama FACEDX yang dapat diakses melalui <https://facedx.web.id>. Sistem dilengkapi error handling yang komprehensif serta antarmuka responsif, sehingga dapat digunakan dengan nyaman baik pada perangkat desktop maupun mobile.

- d. Dari segi efisiensi, model hybrid menunjukkan performa yang sangat baik untuk implementasi real-time. Waktu inferensi rata-rata per citra hanya 72 ms, kemudian ukuran model akhir 43 MB masih sangat ringan, dengan penggunaan RAM tambahan minimal sebesar 0,01 GB dan utilisasi hardware rendah dengan ukuran GPU 0%, CPU 5–10%. Hasil ini membuktikan bahwa model hybrid yang dikembangkan tidak hanya akurat, tetapi juga efisien secara komputasi.

5.2 Saran

Meskipun model yang dikembangkan telah menunjukkan performa yang sangat baik, terdapat beberapa aspek yang dapat dikembangkan lebih lanjut pada penelitian berikutnya, antara lain:

- a. Perluasan dan peningkatan kualitas dataset, khususnya penambahan citra dengan variasi etnis, usia, dan kondisi pencahayaan ekstrem, serta anotasi yang lebih ketat untuk mengurangi ambiguitas antara kelas normal dan *dry*.
- b. Eksplorasi model backbone yang lebih baru seperti EfficientNet-B3/B4, ConvNeXt-Tiny, atau MobileNetV3-Small yang berpotensi memberikan representasi fitur lebih kaya dengan jumlah parameter yang tetap efisien.
- c. Pengembangan fitur tambahan pada aplikasi web, seperti rekomendasi produk skincare personal, riwayat analisis kulit pengguna, serta integrasi dengan kamera smartphone secara real-time.
- d. Pengujian lebih luas di dunia nyata (*user acceptance test*) melibatkan dokter kulit dan pengguna awam untuk mengevaluasi kegunaan klinis serta akurasi persepsi.

Dengan pengembangan lebih lanjut pada aspek-aspek tersebut, diharapkan sistem deteksi jenis kulit wajah berbasis citra digital dapat menjadi alat bantu yang semakin akurat, dan bermanfaat bagi masyarakat luas serta praktisi kesehatan kulit.

REFERENSI

- [1] Zakiah, R. Patmasari, and S. Saidah, "Klasifikasi Jenis Kulit Wajah Menggunakan Metode Convolutional Neural Network (Skin Classification Using Convolutional Neural Network)," *e-Proceeding Eng.*, vol. 8, no. 6, pp. 11610–11616, 2021.
- [2] Y. Du *et al.*, "Facial skin characteristics and concerns in Indonesia: A cross-sectional observational study," *Ski. Res. Technol.*, vol. 28, no. 5, pp. 719–728, Sep. 2022, doi: 10.1111/srt.13189.
- [3] S. D. Kusumaningrum, "KAJIAN PUSTAKA DALAM PENENTUAN TIPE DAN PERMASALAHAN KULIT WAJAH," *J. Sains, Nalar, dan Apl. Teknol. Inf.*, vol. 1, no. 1, Aug. 2021, doi: 10.20885/snati.v1i1.3.
- [4] P. N. Srinivasu, J. G. SivaSai, M. F. Ijaz, A. K. Bhoi, W. Kim, and J. J. Kang, "Classification of Skin Disease Using Deep Learning Neural Networks with MobileNet V2 and LSTM," *Sensors*, vol. 21, no. 8, p. 2852, Apr. 2021, doi: 10.3390/s21082852.
- [5] M. S. Ali, M. S. Miah, J. Haque, M. M. Rahman, and M. K. Islam, "An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models," *Mach. Learn. with Appl.*, vol. 5, p. 100036, Sep. 2021, doi: 10.1016/j.mlwa.2021.100036.
- [6] D. Marya, C. Mustika Sari Ramadhani, and R. Ardiansyah, "Development of an Optimized Facial Skin Type Classification System using CNN MobileNetV2 for Real-Time Smartphone Applications," *Telecommun. Netw. (Jurnal Jar. Telekomun.)*, pp. 1–8, 2025.
- [7] U. M. Prakash *et al.*, "Multi-scale feature fusion of deep convolutional neural networks on cancerous tumor detection and classification using biomedical images," *Sci. Rep.*, vol. 15, no. 1, p. 1105, Jan. 2025, doi: 10.1038/s41598-024-84949-1.
- [8] Dian Anisa Agustina, "KLASIFIKASI CITRA JENIS KULIT WAJAH DENGAN ALGORITMA CONVOLUTIONAL NEURAL NETWORK (CNN) RESNET-50," *J. Ris. Sist. Inf.*, vol. 1, no. 3, pp. 01–07, Jul. 2024, doi: 10.69714/13sbby24.
- [9] A. Ghofur, A. Apriliana, R. A. Ningsih, and N. D. Kamelia, "JUSTIFY : Jurnal Sistem Informasi Ibrahimy Klasifikasi Image Kulit Wajah Berjerawat , Berminyak dan Kulit Sehat Menggunakan Teachable Machine Learning," vol. 4, no. 1, pp. 4–11, 2025, doi: 10.35316/justify.v4i1.7770.
- [10] V. D. Br Sebayang and I. G. N. L. W. Kusuma, "Klasifikasi Jenis Jerawat Berdasarkan Citra Menggunakan Convolutional Neural Network dengan Arsitektur MobileNetV2," *J. FASILKOM*, vol. 14, no. 3, pp. 766–774, Dec. 2024, doi: 10.37859/jf.v14i3.8202.
- [11] S. D. Kusumaningrum and I. Muhimmah, "Analisis Faktor dan Metode

- untuk Menentukan Tipe Kulit Wajah: Tinjauan Literatur,” *J. Teknol. Inf. dan Ilmu Komput.*, vol. 10, no. 4, pp. 753–762, 2023, doi: 10.25126/jtiik.2024106955.
- [12] H. E. Kim, A. Cosa-Linan, N. Santhanam, M. Jannesari, M. E. Maros, and T. Ganslandt, “Transfer learning for medical image classification: a literature review,” *BMC Med. Imaging*, vol. 22, no. 1, p. 69, Dec. 2022, doi: 10.1186/s12880-022-00793-7.
 - [13] Gabrielle Sheila Sylvagno and T. H. Rochadiani, “Skincare Recommendation System Based on Facial Skin Type with Real-Time Weather Integration,” *J. Sisfokom (Sistem Inf. dan Komputer)*, vol. 14, no. 2, pp. 230–237, 2025, doi: 10.32736/sisfokom.v14i2.2355.
 - [14] R. Yohannes and M. E. Al Rivan, “Klasifikasi Jenis Kanker Kulit Menggunakan CNN-SVM,” *J. Algoritma*, vol. 2, no. 2, pp. 133–144, Apr. 2022, doi: 10.35957/algoritme.v2i2.2363.
 - [15] H. Pan, Z. Pang, Y. Wang, Y. Wang, and L. Chen, “A New Image Recognition and Classification Method Combining Transfer Learning Algorithm and MobileNet Model for Welding Defects,” *IEEE Access*, vol. 8, pp. 119951–119960, 2020, doi: 10.1109/ACCESS.2020.3005450.
 - [16] S. N. Ria, M. Walid, and B. A. Umam, “Pengolahan Citra Digital Untuk Identifikasi Jenis Penyakit Kulit Menggunakan Metode Convolutional Neural Network (CNN),” *Energy - J. Ilm. Ilmu-Ilmu Tek.*, vol. 12, no. 2, pp. 9–16, Dec. 2022, doi: 10.51747/energy.v12i2.1118.
 - [17] N. Aprillia, D. P. Martian, T. H. Putri, A. Indriani, and ..., “Analisis Klasifikasi Citra Penyakit Kulit Menggunakan Convolutional Neural Network (MobileNet),” *E-Journal BIAStatistics ...*, pp. 53–60, 2022.
 - [18] D. Anggriandi, E. Utami, and D. Ariatmanto, “Comparative Analysis of CNN and CNN-SVM Methods For Classification Types of Human Skin Disease,” *sinkron*, vol. 8, no. 4, pp. 2168–2178, Oct. 2023, doi: 10.33395/sinkron.v8i4.12831.
 - [19] R. Dandu, M. Vinayaka Murthy, and Y. B. Ravi Kumar, “Transfer learning for segmentation with hybrid classification to Detect Melanoma Skin Cancer,” *Heliyon*, vol. 9, no. 4, p. e15416, Apr. 2023, doi: 10.1016/j.heliyon.2023.e15416.